

Problem 1

测量了 9 对父子的身高，所得数据如下（单位：英寸）

父亲身高 x_i	60	62	64	66	67	68	70	72	74
儿子身高 y_i	63.6	65.2	66	66.9	67.1	67.4	68.3	70.1	70

经计算得： $\sum_{i=1}^9 x_i = 603$, $\sum_{i=1}^9 y_i = 604.6$, $\sum_{i=1}^9 x_i^2 = 40569$, $\sum_{i=1}^9 x_i y_i = 40584.9$, $\sum_{i=1}^9 y_i^2 = 40651.68$
试求：

- 儿子身高 y 关于父亲身高 x 的最小二乘回归方程；
- 取 $\alpha = 0.05$ ，检验儿子的身高 y 与父亲身高 x 之间的线性关系是否显著；
- 若父亲身高 70 英寸，求其儿子的身高的置信度为 95% 的预测区间。

Solution 1

- (a) 设 $y = a + bx$ 则

$$\hat{b} = \frac{n \sum_{i=1}^n x_i y_i - \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right)}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2}$$

$$\hat{a} = \frac{1}{n} \sum_{i=1}^n y_i - \frac{\hat{b}}{n} \sum_{i=1}^n x_i$$

代入数据可得， $\hat{b} = 0.4565$, $\hat{a} = 36.59$ 则儿子身高 y 关于父亲身高 x 的最小二乘回归方程为：

$$y = 0.4565x + 36.59$$

- (b) 先计算几个量：

$$S_{xx} = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 = 168$$

$$S_{yy} = \sum_{i=1}^n y_i^2 - \frac{1}{n} \left(\sum_{i=1}^n y_i \right)^2 = 36.0$$

$$S_{xy} = \sum_{i=1}^n x_i y_i - \frac{1}{n} \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right) = 76.7$$

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n-2} (S_{yy} - \hat{b} S_{xy})} = 0.375$$

若有零假设 $H_0: b = 0$, 则其拒绝域为:

$$|t| = \frac{|\hat{b}|}{\hat{\sigma}} \sqrt{S_{xx}} \geq t_{\alpha/2}(n-2)$$

查表可得: $t_{0.05/2}(n-2) = t_{0.025}(7) = 2.3646$ 现在

$$|t| = \frac{0.4565}{0.375} \times \sqrt{168} = 15.77 > 2.3646$$

故拒绝原假设, 认为回归效果是显著的。

(c) 由公式, 其预测区间为

$$\left(\hat{a} + \hat{b}x_0 \pm t_{\alpha/2}(n-2) \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}} \right)$$

代入数据得, 其儿子的身高的置信度为 95% 的预测区间为

$$(67.545 \pm 0.957)$$

Problem 2

最小二乘法估计是基于均方误差最小化原则推导出来的回归方法, 如果考虑垂直距离平方和最小化, 尝试推导线性回归的斜率和截距的估计量。

Solution 2

设直线方程为 $y = a + bx$, 则残差平方和为

$$R_{\perp}^2 = \sum_{i=1}^n \frac{[y_i - (a + bx_i)]^2}{1 + b^2} \quad (1)$$

求导：

$$\frac{\partial R_{\perp}^2}{\partial a} = \frac{2}{1+b^2} \sum_{i=1}^n [y_i - (a + bx_i)](-1) = 0 \quad (2)$$

$$\frac{\partial R_{\perp}^2}{\partial b} = \frac{2}{1+b^2} \sum_{i=1}^n [y_i - (a + bx_i)](-x_i) + \sum_{i=1}^n \frac{[y_i - (a + bx_i)]^2(-1)(2b)}{(1+b^2)^2} = 0 \quad (3)$$

(2) 式可化为

$$a = \frac{\sum_{i=1}^n y_i - b \sum_{i=1}^n x_i}{n} = \bar{y} - b\bar{x} \quad (4)$$

而 (3) 式即

$$(1+b^2) \sum_{i=1}^n [y_i - (a + bx_i)]x_i + b \sum_{i=1}^n [y_i - (a + bx_i)]^2 = 0 \quad (5)$$

注意到

$$[y - (a + bx)]^2 = y^2 - 2(a + bx)y + (a + bx)^2 = y^2 - 2ay - 2bxy + a^2 + 2abx + b^2x^2 \quad (6)$$

(5) 式可化为

$$(1+b^2) \left(\sum_{i=1}^n x_i y_i - a \sum_{i=1}^n x_i - b \sum_{i=1}^n x_i^2 \right) + b \left(\sum_{i=1}^n y_i^2 - 2a \sum_{i=1}^n y_i - 2b \sum_{i=1}^n x_i y_i + a^2 \sum_{i=1}^n 1 + 2ab \sum_{i=1}^n x_i + b^2 \sum_{i=1}^n x_i^2 \right) = 0 \quad (7)$$

即

$$-b \sum_{i=1}^n x_i^2 + (1-b^2) \sum_{i=1}^n x_i y_i + b \sum_{i=1}^n y_i^2 + a(b^2-1) \sum_{i=1}^n x_i - 2ab \sum_{i=1}^n y_i + ba^2 n = 0 \quad (8)$$

将 (4) 式代入 (8) 式并稍加整理可得：

$$b^2 + \frac{\sum_{i=1}^n y_i^2 - \sum_{i=1}^n x_i^2 + \frac{1}{n}[(\sum_{i=1}^n x_i)^2 - (\sum_{i=1}^n y_i)^2]}{\frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n y_i - \sum_{i=1}^n x_i y_i} b - 1 = 0 \quad (9)$$

若记

$$\begin{aligned}
 B &\equiv \frac{1}{2} \frac{[\sum_{i=1}^n y_i^2 - \frac{1}{n}(\sum_{i=1}^n y_i)^2] - [\sum_{i=1}^n x_i^2 - \frac{1}{n}(\sum_{i=1}^n x_i)^2]}{\frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n y_i - \sum_{i=1}^n x_i y_i} \\
 &= \frac{1}{2} \frac{(\sum_{i=1}^n y_i^2 - n\bar{y}^2) - (\sum_{i=1}^n x_i^2 - n\bar{x}^2)}{n\bar{x}\bar{y} - \sum_{i=1}^n x_i y_i}
 \end{aligned} \tag{10}$$

则

$$b = -B \pm \sqrt{B^2 + 1} \tag{11}$$