



Intelligent Optimization in Chemical Engineering



Hua Zhou

cezhouh@xmu.edu.cn

9/18/2024

College of Chemistry & Chemical Engineering




Cases or Examples

□ Case 1

$$\begin{aligned} \min z &= 6x_1 + 4x_2 \\ \text{s. t. } &\begin{cases} 2x_1 + x_2 \geq 1 \\ 3x_1 + 4x_2 \geq 1.5 \\ x_1, x_2 \geq 0 \end{cases} \end{aligned}$$

Solution:




Optimal solution is $\mathbf{x}^* = (0.5, 0)^T, z^* = 3$

Cases or Examples

□ Case 2

$$\begin{aligned} \max z &= 2x_1 + 2x_2 \\ \text{s. t. } &\begin{cases} x_1 - x_2 \geq -1 \\ -0.5x_1 + x_2 \leq 2 \\ x_1, x_2 \geq 0 \end{cases} \end{aligned}$$

Solution:




The solution set is unbounded

Cases or Examples

□ Case 3

$$\begin{aligned} \max z &= 4x_1 + 8x_2 \\ \text{s.t. } \begin{cases} 2x_1 + 2x_2 \leq 10 \\ -x_1 + x_2 \geq 8 \\ x_1, x_2 \geq 0 \end{cases} \end{aligned}$$

Solution:




The feasible solution set is empty.

Cases or Examples

□ Case 4

$$\max z = 3x_1 + 6x_2$$

$$s. t. \begin{cases} x_1 - x_2 \geq -2 \\ x_1 + 2x_2 \leq 6 \\ x_1, x_2 \geq 0 \end{cases}$$





Feasible solution & optimal solution

□ Feasible domain of the optimization problem

$$\begin{aligned} & \min f(\mathbf{x}) \\ \text{s. t. } & \begin{cases} g_i(\mathbf{x}) \leq 0, & i = 1, 2, \dots, m \\ h_j(\mathbf{x}) = 0, & j = 1, 2, \dots, p \end{cases} \end{aligned}$$

所有满足约束条件的点的集合，称为优化问题的可行域 (Feasible domain)。

可行域中的点称为可行点 (Feasible point)。

使得目标函数取得最小（大）的点称为优化问题的最优解 (optimal solution)。



Feasible solution & optimal solution

□ Feasible domain of the optimization problem

$$\min z = (x_1 - 3)^2 + (x_2 - 2)^2 + 1$$

$$s. t. \begin{cases} x_1^2 - x_2 - 3 \leq 0 \\ x_2 - 1 \leq 0 \\ x_1 \geq 0 \end{cases}$$

仅仅从目标函数的角度出发，如果不考虑约束条件，最优解为 $x_1^* = 3, x_2^* = 2$ ，得到目标函数的图形及其等值线如下：





Feasible solution & optimal solution

□ Feasible domain of the optimization problem

$$\min z = (x_1 - 3)^2 + (x_2 - 2)^2 + 1$$

$$s. t. \begin{cases} x_1^2 - x_2 - 3 \leq 0 \\ x_2 - 1 \leq 0 \\ x_1 \geq 0 \end{cases}$$

考虑约束条件，那么该优化问题的解必须在可行域内考虑，根据约束条件得到的可行域如下所示，进而根据下右图可以得出优化问题的最优解为 $x_1^* = 2, x_2^* = 1$,



Extremum theory


□ 一元函数

一元函数定义区间 $[a, b]$ 上 $y = f(x)$, 在点 x_1 附近有:
$$f(x) \leq f(x_1)$$

在点 x_2 附近有:

$$f(x) \geq f(x_2)$$

点 x_1 、 x_2 分别称为函数 $f(x)$ 的极大值点与极小值点（局部概念）。如果从整个定义区间考虑，函数 $f(x)$ 在 $x = b$ 处达到最大， $x = x_2$ 处达到最小，则 $x = x_2, x = b$ 分别称为函数 $f(x)$ 的最小值点和最大值点。





Extremum theory

□ 一元函数

若极值点有切线，则该点切线斜率为零，即极值点满足：

$$f'(x) = 0$$

该条件称为极值点的必要条件，满足此条件的点称为函数的平稳点。

利用Taylor公式将函数在(a, b)内某点 x_0 展开到二阶项：

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2}f''(x_0)(x - x_0)^2 + O(|x - x_0|^3)$$

若 x_0 为极小点

$$f'(x_0) = 0 \cup f(x) \geq f(x_0) \Rightarrow f''(x_0) \geq 0$$

因此得到极小点的二阶必要条件：

$$f'(x_0) = 0, \quad f''(x_0) \geq 0$$

同理，极大点的二阶必要条件

$$f'(x_0) = 0, \quad f''(x_0) \leq 0$$



Extremum theory

□ 二元函数

二元函数 $z = f(x, y)$ 表示空间曲面, 若在点 $p_0(x_0, y_0)$ 的函数值 $f(x_0, y_0)$ 与 p_0 点附近任意点 (x, y) 的函数值满足

$$f(x, y) \leq f(x_0, y_0)$$

则称点 $p_0(x_0, y_0)$ 为函数 $f(x, y)$ 的极大点, $f(x_0, y_0)$ 称为函数的极大值。点 p_0 附近存在某个正数 δ , 满足不等式

$$\sqrt{(x - x_0)^2 + (y - y_0)^2} < \delta$$

的全体点的集合, 也称为点 $p_0(x_0, y_0)$ 的 δ 邻域。同理对点 p_0 的 δ 邻域内任意点 (x, y) 有

$$f(x, y) \geq f(x_0, y_0)$$

则称点 $p_0(x_0, y_0)$ 为函数 $f(x, y)$ 极小点, $f(x_0, y_0)$ 称为函数的极小值。

Extremum theory

□ 二元函数

若函数 $z = f(x, y)$ 在极值点 $p_0(x_0, y_0)$ 有切平面，则切平面与 xoy 面平行，即满足


$$f'_x(x_0, y_0) = 0, f'_y(x_0, y_0) = 0$$

二元函数极值的一阶必要条件，满足该条件的点称为平稳点。由微积分知识可知，函数 $f(x, y)$ 的梯度为：

$$\nabla f(x, y) = \text{grad} f = (f'_x, f'_y)^T$$

极值点可描述为函数在该点梯度为零

$$\nabla f(x_0, y_0) = 0$$





Extremum theory

□ 二元函数

将 $f(x, y)$ 在点 (x_0, y_0) 处Taylor展开


$$\begin{aligned} f(x, y) &= f(x_0, y_0) + f'_x(x_0, y_0)(x - x_0) + f'_y(x_0, y_0)(y - y_0) \\ &+ \frac{1}{2} [f''_{xx}(x_0, y_0)(x - x_0)^2 + 2f''_{xy}(x_0, y_0)(x - x_0)(y - y_0) + f''_{yy}(x_0, y_0)(y - y_0)^2] \\ &+ O(|x - x_0|^2 + |y - y_0|^2) \end{aligned}$$

根据极值点的条件

$$\nabla f(x_0, y_0) = 0$$

则该点属于极大值或极小值由下面式子的正负号决定

$$\begin{aligned} I &= f''_{xx}(x_0, y_0)(x - x_0)^2 + 2f''_{xy}(x_0, y_0)(x - x_0)(y - y_0) \\ &+ f''_{yy}(x_0, y_0)(y - y_0)^2 \end{aligned}$$





Extremum theory

□ 二元函数

$$I = f_{xx}''(x_0, y_0)(x - x_0)^2 + 2f_{xy}''(x_0, y_0)(x - x_0)(y - y_0) \\ + f_{yy}''(x_0, y_0)(y - y_0)^2$$

令

$$A = f_{xx}''(x_0, y_0), B = f_{xy}''(x_0, y_0), C = f_{yy}''(x_0, y_0), h = x - x_0, k = y - y_0$$

则

$$I = Ah^2 + 2Bhk + Ck^2 = \frac{1}{A}(A^2h^2 + 2ABhk + B^2k^2 - B^2k^2 + ACk^2) \\ = \frac{1}{A}[(Ah + Bk)^2 + k^2(AC - B^2)]$$

or

$$I = Ah^2 + 2Bhk + Ck^2 = \frac{1}{C}(C^2k^2 + 2CBhk + B^2h^2 - B^2h^2 + ACh^2) \\ = \frac{1}{C}[(CK + Bh)^2 + h^2(AC - B^2)]$$



Extremum theory

□ 二元函数

$$I = \frac{1}{A}[(Ah + Bk)^2 + k^2(AC - B^2)] = \frac{1}{C}[(Ck + Bh)^2 + h^2(AC - B^2)]$$

若函数在点 (x_0, y_0) 处取得极小值, 则在点 (x_0, y_0) 附近有

$$f(x, y) \geq f(x_0, y_0)$$

因此有 $I \geq 0$, 又由于 $(Ah + Bk)^2 \geq 0$ 、 $(Ck + Bh)^2 \geq 0$, 为此可以取 h, k 满足 $Ah + Bk = 0$ 或 $Ck + Bh = 0$, 那么

$$A > 0 \text{ (or } C > 0), AC - B^2 \geq 0$$

称为极小点的二阶必要条件, 同理, 极大点的二阶必要条件为

$$A < 0 \text{ (or } C < 0), AC - B^2 \geq 0$$



Extremum theory

□ 二元函数

写成矩阵形式：

$$H = \begin{bmatrix} f''_{xx}(x_0, y_0) & f''_{xy}(x_0, y_0) \\ f''_{xy}(x_0, y_0) & f''_{yy}(x_0, y_0) \end{bmatrix} = \begin{bmatrix} A & B \\ B & C \end{bmatrix}$$

称为 $f(x, y)$ 在点 (x_0, y_0) 的Hessian (海赛) 矩阵, 则

$$I = [h \quad k] \begin{bmatrix} A & B \\ B & C \end{bmatrix} \begin{bmatrix} h \\ k \end{bmatrix}$$

对于任意的 h, k , 若 $I \geq 0$, 则矩阵 H 半正定, 若 $I \leq 0$, 则矩阵 H 半负定。

因此极值二阶必要及充分条件为：

- 必要条件—若点 (x_0, y_0) 为函数极小(大)点, 则海赛矩阵半正(负)定
- 充分条件—若点 (x_0, y_0) 函数一阶偏导为零, 且海赛矩阵正(负)定, 则该点的函数值极小(大)。



Extremum theory

□ n元函数

n元函数 $f(x_1, x_2, \dots, x_n)$ 记为 $f(\mathbf{x})$ ，二元函数的极值结论可推广到n元函数。点 $\mathbf{x}^0(x_1^0, x_2^0, \dots, x_n^0)$ 的 δ 邻域内，对于任意点 $\mathbf{x}$ （邻域数学表示为

$$\sqrt{(x_1 - x_1^0)^2 + (x_2 - x_2^0)^2 + \dots + (x_n - x_n^0)^2} < \delta$$
 若有

$$f(\mathbf{x}) \geq f(\mathbf{x}^0)$$

则称 $\mathbf{x}^0$ 为函数的极小点， $f(\mathbf{x}^0)$ 为极小值。函数 $f(\mathbf{x})$ 的梯度为

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)^T$$

为一个n维向量，满足 $\nabla f(\mathbf{x}) = \mathbf{0}$ 的点为 $f(\mathbf{x})$ 的平稳点。



Extremum theory

□ n元函数

$f(x)$ 的海赛矩阵为:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1^2} & \frac{\partial f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial f}{\partial x_1 \partial x_n} \\ \frac{\partial f}{\partial x_2 \partial x_1} & \frac{\partial f}{\partial x_2^2} & \cdots & \frac{\partial f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial f}{\partial x_n \partial x_1} & \frac{\partial f}{\partial x_n \partial x_2} & \cdots & \frac{\partial f}{\partial x_n^2} \end{bmatrix}$$

海赛矩阵属于一个 $n \times n$ 矩阵, 记作 $H(x)$ 。



Extremum theory

□ n元函数

$f(\mathbf{x})$ 在点 $\mathbf{x}^0(x_1^0, x_2^0, \dots, x_n^0)$ 处二阶Taylor展开式为:

$$f(\mathbf{x}) = f(\mathbf{x}^0) + \nabla f(\mathbf{x}^0)^T (\mathbf{x} - \mathbf{x}^0) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^0)^T H(\mathbf{x}^0) (\mathbf{x} - \mathbf{x}^0) + O(|\mathbf{x} - \mathbf{x}^0|^2)$$

式中 $\mathbf{x} - \mathbf{x}^0 = (x_1 - x_1^0, x_2 - x_2^0, \dots, x_n - x_n^0)$, $H(\mathbf{x}^0)$ 为函数在点 $\mathbf{x}^0$ 处的海赛矩阵。

设 $\mathbf{x}^0$ 为 $f(\mathbf{x})$ 可行域 D 内一点, $\mathbf{d}$ 为向量, 若存在正数 α_0 , 对所有的 $\alpha(0 \leq \alpha \leq \alpha_0)$, 满足 $\mathbf{x}^0 + \alpha \mathbf{d} \in D$, 则 $\mathbf{d}$ 称为 $f(\mathbf{x})$ 在点 $\mathbf{x}^0$ 的可行方向。



Extremum theory

□ n元函数

多元函数极值条件

- 一阶必要条件—设 $f(\mathbf{x})$ 连续可微, $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 可行域的极小点, $\mathbf{d}$ 为 $f(\mathbf{x})$ 在 $\mathbf{x}^*$ 处的任意可行方向, 则有

$$\nabla f(\mathbf{x}^*)\mathbf{d} \geq 0$$

- 二阶必要条件—设 $f(\mathbf{x})$ 二次连续可微, $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 可行域的极小点, 且 $\nabla f(\mathbf{x}^*) = 0$, 则有

$$\mathbf{d}^T H(\mathbf{x}^*)\mathbf{d} \geq 0$$

$\mathbf{d}$ 为任意可行方向。说明 $f(\mathbf{x})$ 在平稳点处极小, 则海赛矩阵该点半正定。

- 二阶充分条件—若 $\nabla f(\mathbf{x}^*) = 0$, $H(\mathbf{x}^*)$ 正定, 则 $\mathbf{x}^*$ 是 $f(\mathbf{x})$ 的极小点。
- 函数极大值也有类似的结论



Quadratic form and positive definite matrix

□ Quadratic form

二次型指含有 n 个变量 $x_1, x_2, \dots, x_n$ 的一个二次齐次函数

$$\begin{aligned} f &= a_{11}x_1^2 + a_{22}x_2^2 + \dots + 2a_{12}x_1x_2 + 2a_{13}x_1x_3 + \dots + 2a_{n-1n}x_{n-1}x_n \\ &= \sum_{i,j=1}^n a_{ij}x_ix_j \quad (a_{ij} = a_{ji}) \end{aligned}$$

二次型可写为：

$$\begin{aligned} f &= x_1(a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n) + \\ &\quad x_2(a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n) + \\ &\quad \dots\dots\dots + \\ &\quad x_n(a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n) \end{aligned}$$



Quadratic form and positive definite matrix

□ Quadratic form

f 的系数可以确定一个对称矩阵

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

反过来任给一个 n 阶对称矩阵 A , 可以确定一个二次型 $\sum_{j,i,j=1}^n a_{ij}x_ix_j$, 利用矩阵, 二次型又可写为

$$\begin{aligned} f &= [x_1, x_2, \cdots, x_n] \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \\ \cdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n \end{bmatrix} \\ &= [x_1, x_2, \cdots, x_n] \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \cdots \\ x_n \end{bmatrix} = \mathbf{x}^T A \mathbf{x} \end{aligned}$$



Quadratic form and positive definite matrix

□ Quadratic form

例如二次型 $f = x^2 + 2xy + 4xz + 3y^2 + yz + 7z^2$ 用矩阵记号表示为:

$$f = [x \quad y \quad z] \begin{bmatrix} 1 & 1 & 2 \\ 1 & 3 & 1/2 \\ 2 & 1/2 & 7 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix}$$

□ Positive definite matrix

- 对不全为零的任何实数, 二次型 $f = \sum_{i,j=1}^n a_{ij}x_i x_j$, ($a_{ij} = a_{ji}$) 的值都是正数 ($f > 0$), 则称此二次型为正定, 其对应矩阵称为正定矩阵。
- 若对不全为零的任何实数, 二次型 $f = \sum_{i,j=1}^n a_{ij}x_i x_j$, ($a_{ij} = a_{ji}$) 的值都非负 ($f \geq 0$), 则称此二次型为半正定, 其对应矩阵称半正定矩阵。
- 若 $f < 0$, 二次型为负定, 其对应矩阵称为负定矩阵, 若 $f \leq 0$, 二次型为半负定, 其对应矩阵称为半负定矩阵。



Quadratic form and positive definite matrix

□ Positive definite matrix

➤ 正定矩阵A的充分必要条件是所有主子式均大于零，即

$$a_{11} > 0, \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} > 0, \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} > 0, \dots$$

➤ 负定矩阵A的充分必要条件是-A是正定的。

Convex sets & convex function



□ Definition of convex sets

➤ 凸集

设 D 为 R^n 中的集合，任取两点 $\mathbf{x}^1, \mathbf{x}^2 \in D$ ，若对任意 $\alpha (0 \leq \alpha \leq 1)$

$$\mathbf{x} = \alpha \mathbf{x}^1 + (1 - \alpha) \mathbf{x}^2 \in D$$

则称 D 属于凸集。





Convex sets & convex function


□ Definition of convex sets

证明：平面上矩形区域 $D = \{x, y | a_1 \leq x \leq b_1, a_2 \leq y \leq b_2\}$ 是凸集。

如图在 D 内任取2点 $P(x_p, y_p), Q(x_q, y_q)$ ，设 $R(x_R, y_R)$ 为线段 PQ 上的点，则有

$$x_R = \alpha x_p + (1 - \alpha)x_q$$

$$y_R = \alpha y_p + (1 - \alpha)y_q$$



其中 $0 \leq \alpha \leq 1$ ，此外， $a_1 \leq x_p$ (or x_q) $\leq b_1, a_2 \leq y_p$ (or y_q) $\leq b_2$ ，则

$$\alpha a_1 + (1 - \alpha)a_1 \leq x_R \leq \alpha b_1 + (1 - \alpha)b_1$$

$$\alpha a_2 + (1 - \alpha)a_2 \leq y_R \leq \alpha b_2 + (1 - \alpha)b_2$$

即

$$a_1 \leq x_R \leq b_1$$

$$a_2 \leq y_R \leq b_2$$

$$\Rightarrow R \in D$$



Convex sets & convex function

□ 凸组合

设 $x_1, x_2, \dots, x_k$ 是欧氏空间 R^n 中的 k 个点, 若存在实数 $\lambda_1, \lambda_2, \dots, \lambda_k$, $\lambda_i \in [0,1]$ 且 $\sum_{i=1}^k \lambda_i = 1$, 有

$$x = \lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k$$

则称 x 为 $x_1, x_2, \dots, x_k$ 的一个凸组合。

若存在实数 $\lambda_i \in (0,1)$ 且 $\sum_{i=1}^k \lambda_i = 1$, 有

$$x = \lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k$$

则称 x 为 $x_1, x_2, \dots, x_k$ 的一个严格凸组合。

Convex sets & convex function


□ Definition of convex function

设 $f(x)$ 定义在凸集 D 上的函数, 若对 D 中任意两点 u 、 v 及属于 $[0,1]$ 上任意实数 α , $f(x)$ 满足下述关系

$$f[\alpha u + (1 - \alpha)v] \leq \alpha f(u) + (1 - \alpha)f(v)$$

则称 $f(x)$ 为凸函数。

对一元函数而言, 如右图所示, 上述定义表明两点间的割线位于曲线上面。





Convex sets & convex function

□ Property of convex function

定理1 连续可微的函数 $f(x)$ 是凸集 D 上的凸函数其充要条件为：对于任意 $x, y \in D$ 都有

$$f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

证明：先证必要性。设 $f(x)$ 为凸函数，则根据定义

$$f[\alpha y + (1 - \alpha)x] \leq \alpha f(y) + (1 - \alpha)f(x)$$

$$f[\alpha y + (1 - \alpha)x] - f(x) \leq \alpha f(y) - \alpha f(x)$$

$$\frac{f[\alpha y + (1 - \alpha)x] - f(x)}{\alpha} \leq f(y) - f(x)$$

$$\because f[\alpha y + (1 - \alpha)x] = f[x + \alpha(y - x)]$$

$$\frac{f[x + \alpha(y - x)] - f(x)}{\alpha(y - x)} (y - x) \leq f(y) - f(x)$$

令 $\alpha \rightarrow 0$ 得

$$\nabla f(x)^T (y - x) \leq f(y) - f(x)$$



Convex sets & convex function

□ Property of convex function

再证充分性。在 D 内任取两点 $\mathbf{x}^1, \mathbf{x}^2$, 设 $\bar{\mathbf{x}} = \alpha\mathbf{x}^1 + (1 - \alpha)\mathbf{x}^2$, $0 \leq \alpha \leq 1$ 。
则根据式 $f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T(\mathbf{y} - \mathbf{x})$, 若式中 $\mathbf{y} = \mathbf{x}^1$, $\mathbf{x} = \bar{\mathbf{x}}$, 则有

$$f(\mathbf{x}^1) \geq f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})^T(\mathbf{x}^1 - \bar{\mathbf{x}}) \quad (1)$$

同理 $\mathbf{y} = \mathbf{x}^2$, $\mathbf{x} = \bar{\mathbf{x}}$, 有

$$f(\mathbf{x}^2) \geq f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})^T(\mathbf{x}^2 - \bar{\mathbf{x}}) \quad (2)$$

用 α 乘以式(1), $(1 - \alpha)$ 乘以式(2), 然后相加得

$$\begin{aligned} & \alpha f(\mathbf{x}^1) + (1 - \alpha)f(\mathbf{x}^2) \\ & \geq \alpha[f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})^T(\mathbf{x}^1 - \bar{\mathbf{x}})] + (1 - \alpha)[f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})^T(\mathbf{x}^2 - \bar{\mathbf{x}})] \\ & = f(\bar{\mathbf{x}}) + \alpha\nabla f(\bar{\mathbf{x}})^T(\mathbf{x}^1 - \bar{\mathbf{x}}) + (1 - \alpha)\nabla f(\bar{\mathbf{x}})^T(\mathbf{x}^2 - \bar{\mathbf{x}}) \\ & = f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})^T[\alpha\mathbf{x}^1 + (1 - \alpha)\mathbf{x}^2 - \bar{\mathbf{x}}] = f(\bar{\mathbf{x}}) = f[\alpha\mathbf{x}^1 + (1 - \alpha)\mathbf{x}^2] \end{aligned}$$



Convex sets & convex function

□ Property of convex function

$$\alpha f(\mathbf{x}^1) + (1 - \alpha)f(\mathbf{x}^2) \geq f[\alpha\mathbf{x}^1 + (1 - \alpha)\mathbf{x}^2]$$

$\therefore f(\mathbf{x})$ is convex function

定理 2 设 $f(\mathbf{x})$ 连续可微, 且为凸集 D 上的凸函数, 则 $f(\mathbf{x})$ 在 D 上的极小点也是 $f(\mathbf{x})$ 在 D 上的最小点。

证明 设 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 在 D 上的极小点, 由定理1, 对于任意 $\mathbf{y} \in D$ 有

$$f(\mathbf{y}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T (\mathbf{y} - \mathbf{x}^*)$$

由 $\mathbf{x}^*, \mathbf{y}, (\mathbf{y} - \mathbf{x}^*) \in D$ 及 D 是凸集, 因此 $\mathbf{y} - \mathbf{x}^*$ 为 $f(\mathbf{x})$ 在 $\mathbf{x}^*$ 的一个可行方向, 根据极小值的一阶必要条件得 $\nabla f(\mathbf{x}^*)(\mathbf{y} - \mathbf{x}^*) \geq 0$

$$\therefore f(\mathbf{y}) \geq f(\mathbf{x}^*)$$

由于 $\mathbf{y}$ 的任意性, 即定理2得证。



Convex sets & convex function

□ Property of convex function

定理 3 设 $f(x)$ 二阶连续可微, 则 $f(x)$ 是凸函数充要条件为: $f(x)$ 的海赛矩阵 $H(x)$ 总是半正定的。

证明 先证充分性。由Taylor展开

$$f(y) = f(x) + \nabla f(x)^T (y - x) + \frac{1}{2} (y - x)^T H(\bar{x}) (y - x)$$

$\bar{x}$ 为 x 与 y 之间的一点, 若 $H(x)$ 半正定, 则二次型 $(y - x)^T H(\bar{x}) (y - x) \geq 0$

$$\therefore f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

根据定理1可知, $f(x)$ 为凸函数。



Convex sets & convex function

□ Property of convex function

证明 再证必要性。反证法，若 $f(x)$ 的海赛矩阵在某点 x 是负定的，则有 y 满足

$$(y - x)^T H(x)(y - x) < 0$$

取 y 与 x 充分接近，使Taylor展开式中二次项及高于二次项的所有项之和为负，则得

$$f(y) \leq f(x) + \nabla f(x)^T (y - x)$$

这与 $f(x)$ 是凸函数的定义相矛盾。

以上3个定理，讨论极值问题时非常重要，定理2对于凸函数，只要求出极小点，也就得到了最小点。定理3给出凸函数的一个判定方法。



Convex sets & convex function

□ Property of convex function (Cases)

如函数 $f(\mathbf{x}) = 60 - 10x_1 - 4x_2 + x_1^2 + x_2^2 - x_1x_2$, 可求出其海赛(Hessian)矩阵为

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$$

因为 H 是正定的, 所以 $f(\mathbf{x})$ 是一个凸函数。只要求出其平稳点 (即梯度 $\nabla f(\mathbf{x}) = 0$ 的点), 且此平稳点在可行域内, 那么它就是问题的最优解。



Quasi-linearization

用线性函数近似非线性函数，称为拟线性化。

□ 线性内插

先讨论一元函数，设有一元函数 $y = f(x)$ ，已知点 x_1, x_2 上的函数值 $f(x_1), f(x_2)$ 。 x_1, x_2 之间的任意点 x 可表示为

$$x = \mu x_1 + (1 - \mu)x_2 \quad (0 \leq \mu \leq 1)$$

x_1, x_2 称为节点，在 x_1, x_2 之间若用线性函数近似 $f(x)$ 则有

$$f(x) = f[\mu x_1 + (1 - \mu)x_2] \approx \mu f(x_1) + (1 - \mu)f(x_2)$$

原来的变量 x 变成了新变量 μ ， $0 \leq \mu \leq 1$ 。若记 $\mu_1 = \mu, \mu_2 = 1 - \mu$ ，则

$$f(x) = \mu_1 f(x_1) + \mu_2 f(x_2)$$

式中 $\mu_1, \mu_2 \geq 0$ ，且 $\mu_1 + \mu_2 = 1$ 。这种近似方法称为线性内插。



Quasi-linearization

□ 线性内插

上述结论可推广到利用 p 个点 $x_1, x_2, \dots, x_p$ 的函数值求 $f(x)$ 的线性近似式。不妨设 p 个点中 x_1 最小, x_p 最大, 则 x_1, x_p 之间任意点 x 可表示为

$$x = \sum_{i=1}^p \mu_i x_i$$

式中 $\mu_i \geq 0$, 且 $\sum_{i=1}^p \mu_i = 1$ 在点 x_1, x_p 之间函数 $f(x)$ 有近似式

$$f(x) = f\left(\sum_{i=1}^p \mu_i x_i\right) \approx \sum_{i=1}^p \mu_i f(x_i)$$

因此一元函数的近似函数是 $\mu_1, \mu_2, \dots, \mu_p$ 等 p 个变量的线性函数。



Quasi-linearization

□ 线性内插

n 元函数的情形, 设有 n 元函数 $f(\mathbf{x})$, 已知 n 维空间的两点 $\mathbf{x}^1$ 和 $\mathbf{x}^2$, 则线段 $\mathbf{x}^1\mathbf{x}^2$ 上任意点 $\mathbf{x}$ 可表示为 $\mathbf{x} = \mu\mathbf{x}^1 + (1 - \mu)\mathbf{x}^2$, 因此函数 $f(\mathbf{x})$ 有线性近似式

$$f(\mathbf{x}) = f[\mu\mathbf{x}^1 + (1 - \mu)\mathbf{x}^2] \approx \mu f(\mathbf{x}^1) + (1 - \mu)f(\mathbf{x}^2)$$

式中 $0 \leq \mu \leq 1$ 。对不在同一直线上的三点 $\mathbf{x}^1, \mathbf{x}^2, \mathbf{x}^3$, 它们所组成的三角形区域内任意点 $\mathbf{x}$ 可表示为

$$\mathbf{x} = \mu_1\mathbf{x}_1 + \mu_2\mathbf{x}_2 + \mu_3\mathbf{x}_3$$

式中 $\mu_1, \mu_2, \mu_3 \geq 0$, 且 $\mu_1 + \mu_2 + \mu_3 = 1$, 因此对于三角形区域内任一点 $\mathbf{x}$, $f(\mathbf{x})$ 的线性近似式

$$f(\mathbf{x}) = f\left(\sum_{i=1}^3 \mu_i \mathbf{x}^i\right) \approx \sum_{i=1}^3 \mu_i f(\mathbf{x}^i)$$



Quasi-linearization

□ 线性内插

一般情况下, 若 x 满足

$$x = \sum_{i=1}^p \mu_i x^i$$

式中 $0 \leq \mu_i \leq 1, i = 1, 2, \dots, p$, 且 $\sum_{i=1}^p \mu_i = 1$, 则 x 表示由 $x^i (i = 1, 2, \dots, p)$ 所组成的凸多边形或多面体中的一点, 对这样的点 x 所对应的 $f(x)$ 同样有线性近似式

$$f(x) = f\left(\sum_{i=1}^p \mu_i x^i\right) \approx \sum_{i=1}^p \mu_i f(x^i)$$



Quasi-linearization

□ 线性展开

对一般的 n 元函数 $f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$, 可以在一点 $\mathbf{x}^0 = (x_1^0, x_2^0, \dots, x_n^0)$ 附近Taylor展开, 略去二次项以上的高次项, 即可得到线性展开式

$$\begin{aligned} f(\mathbf{x}) &\approx f(\mathbf{x}^0) + \nabla f(\mathbf{x}^0)^T (\mathbf{x} - \mathbf{x}^0) \\ &= f(\mathbf{x}^0) + \frac{\partial f(\mathbf{x}^0)}{\partial x_1} (x_1 - x_1^0) + \dots + \frac{\partial f(\mathbf{x}^0)}{\partial x_n} (x_n - x_n^0) \end{aligned}$$

上式称为 $f(\mathbf{x})$ 在点 $\mathbf{x}^0$ 处的线性展开, 或者称为 $f(\mathbf{x})$ 在点 $\mathbf{x}^0$ 处的线性逼近。显然它是 $\mathbf{x}$ 的线性函数。

利用线性展开, 可将非线性目标函数或非线性约束条件线性化, 将原来的非线性优化问题转化为线性优化问题。



Search algorithm

□ 一维搜索法

一维搜索问题针对一元函数求极值，比如一元函数的极小值问题

$$\min f(x)$$

不仅是简单优化问题，且广泛应用于多变量优化问题中。缺乏高性能计算技术之前，最优化方法主要采用解析法，即利用必要条件的解析法求取目标函数导数确定极值点从而求出目标函数的值。如求解简单问题：

$$\min f(x) = x^2 - 2x + 1$$

先使 $\left. \frac{df(x)}{dx} \right|_{x=x^*} = 0 = 2x^* - 2 \Rightarrow x^* = 1$ ，再用充分条件检验 x^* 确保目

标函数值最小，即 $\left. \frac{d^2f(x)}{dx^2} \right|_{x=x^*} = 2 > 0$ ，说明 $x = x^* = 1$ 时为最小值点；

最后求 $x^* = 1$ 时函数值即 $f(x^*) = 0$



Search algorithm

□ 一维搜索法

➤ 收敛(Convergence)

一个算法具有较好的收敛性，还需要较快的收敛速度，收敛速度常用收敛的阶来度量，若 k 从某个 k_0 开始有：

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \leq c \quad (0 \leq c \leq 1)$$

称序列 x_k 为线性收敛(Linear convergence)或一阶收敛。

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^\alpha} \leq c \quad (1 < \alpha < 2, c > 0)$$

称序列 x_k 为超线性收敛(Hyper-linear convergence)。



Search algorithm

□ 一维搜索法

➤ 收敛(Convergence)

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^2} \leq c \quad (c > 0)$$

称序列 x_k 为二阶收敛(Quadratic convergence)。

➤ 终止准则

- 根据变量点接近的情况来判别：

$$\frac{\|x_{k+1} - x_k\|}{\|x_k\|} < \varepsilon_1 \quad \text{when } \|x_k\| \geq \varepsilon_2$$

时认为 $x_{k+1} \approx x^*$



Search algorithm

□ 一维搜索法

➤ 终止准则

- 目标函数值下降的情况判别：

$$\frac{|f(x_{k+1}) - f(x_k)|}{|f(x_k)|} < \varepsilon_1 \quad \text{when} \quad |f(x_k)| \geq \varepsilon_2$$

时认为 $x_{k+1} \approx x^*$

- 若算法中用到梯度，则利用梯度大小来判别如：

$$\|\nabla f(x_k)\| < \varepsilon_3$$

时认为算法已收敛。



Search algorithm

□ 一维搜索法

➤ 终止准则

$\varepsilon_1, \varepsilon_2, \varepsilon_3$ 为事先给定精度要求，通常根据具体情况取 10^{-3} 到 10^{-5} 的值。三种终止准则均有局限性。例如第一种遇到陡坡时(如下左图)可能使迭代过早结束。采用第二种遇到目标函数等值线的平坦部分时(如下右图)也可能使迭代过早结束。而采用梯度信息时可能使迭代在鞍点结束。一般可同时采用两种准则。

防止迭代很多次还达不到预定精度，可规定最大迭代次数。





Search algorithm

□ 一维搜索法

为了不计算函数导数，可采用搜索算法，也可以说是迭代法(Iterative algorithm)，即从某初始点出发，逐次沿目标函数减少（极小值优化问题）或增大（极大值优化问题）的方向移动。一维搜索也称为线性搜索(linear search)，常用的有区间消去法，即不断缩减最优点所在区间而求得最优点的方法，主要介绍黄金分割法(Golden section method)。

► Golden section method

又称0.618法，其基本思想按照对称、稳定的选点法则将区间分割，进而按照固定比例确定保留区间，区间缩短率与计算次数呈指数关系，其收敛速度较快，对函数形式无特殊要求，计算简单。



Search algorithm

□ 一维搜索法-Golden section method

假设搜索区间为 $[a, b]$ ，即搜索区间长度为 $L = b - a$ ，将该区间分为两段，长段为 x ，短段为 $L - x$ ，该搜索方法的特点为每次区间缩小的比例均为一个常数，假设为 μ ，则分割比满足以下关系：

$$\frac{L}{x} = \frac{x}{L - x} = \frac{1}{\mu}$$

$$\therefore \frac{x}{L} = \frac{1 - \frac{x}{L}}{\frac{x}{L}} = \mu$$

$$\therefore \left(\frac{x}{L}\right)^2 + \frac{x}{L} - 1 = 0$$





Search algorithm

□ 一维搜索法-Golden section method

$$\left(\frac{x}{L}\right)^2 + \frac{x}{L} - 1 = 0$$

$$\therefore \frac{x}{L} = \mu$$

$$\Rightarrow \mu^2 + \mu - 1 = 0 \Rightarrow \mu = \frac{-1 + \sqrt{5}}{2} \approx 0.618$$

✓ 计算步骤

- ① 根据问题要求和问题分析建立目标函数模型，确定原始搜索区间 $[a_0, b_0]$ ，给定精度 ε_1 ， ε_2 ，其中 ε_1 为函数值精度， ε_2 为决策变量精度， x_2 和 x_1 分别为左右点，计算过程需分别满足



Search algorithm

□ 一维搜索法-Golden section method

$$\left| \frac{f(x_1^{(k)}) - f(x_2^{(k)})}{f(x_1^{(k)})} \right| \leq \varepsilon_1$$
$$\left| \frac{x_1^{(k)} - x_2^{(k)}}{x_1^{(k)}} \right| \leq \varepsilon_2$$

② $k = 0$, 第一次计算

右点值 $x_1^{(0)} = a_0 + 0.618(b_0 - a_0)$, 左点值 $x_2^{(0)} = b_0 - 0.618(b_0 - a_0)$
右点函数值 $f(x_1^{(0)})$, 左点函数值 $f(x_2^{(0)})$

③ $k \geq 1$, 第 $k + 1$ 次计算

右点值 $x_1^{(k)} = a_k + 0.618(b_k - a_k)$, 左点值 $x_2^{(k)} = b_k - 0.618(b_k - a_k)$
右点函数值 $f(x_1^{(k)})$, 左点函数值 $f(x_2^{(k)})$



Search algorithm

□ 一维搜索法-Golden section method

✓ 计算步骤

④ 函数值比较，确定保留区间，求新区间各点

当 $f(x_1^{(k)}) \geq f(x_2^{(k)})$ ，右大于左，则消右留左，新求左点，新区间各点为：左端点 $a_{k+1} = a_k$ ，右端点 $b_{k+1} = x_1^{(k)}$ ，右点 $x_1^{(k+1)} = x_2^{(k)}$ ，新的左点 $x_2^{(k+1)} = b_{k+1} - 0.618(b_{k+1} - a_{k+1})$ 。


当 $f(x_1^{(k)}) < f(x_2^{(k)})$ ，左大于右，则消左留右，新求右点，新区间各点为：左端点 $a_{k+1} = x_2^{(k)}$ ，右端点 $x_2^{(k+1)} = x_1^{(k)}$ ，右点 $b_{k+1} = b_k$ ，新的右点 $x_1^{(k+1)} = a_{k+1} + 0.618(b_{k+1} - a_{k+1})$ 。

Search algorithm

□ 一维搜索法-Golden section method

✓ 计算步骤

- ⑤ 精度判别。将新区间内左右点及其函数值分别用步骤①中的判别式判断，若都满足精度要求则终止计算，否则重复步骤③-⑤，直到满足精度要求为止。





Search algorithm

□ 一维搜索法-Golden section method (Code)

```
clear all;
clc;
lower = 1;
upper = 7;
f = @(x) x^2-7*x+10;
e = 0.01;
while((upper - lower) >= e)
    alpha1 = lower + 0.382 * (upper - lower);
    alpha2 = lower + 0.618 * (upper - lower);
    if f(alpha1) < f(alpha2)
        upper = alpha2;
    else
        lower = alpha1;
    end
end
X = (lower + upper) / 2;
disp(['optimal solution: X = ',num2str(X)]);
disp(['optimal value: f(X) = ',num2str(f(X))]);
```



Search algorithm

□ 一维搜索法-Golden section method (Code)

```
function [k,x,result]=goldensearch(fun1,interval,epsilon)
a=interval(1); b=interval(2); x1=a+0.382*(b-a); x2=a+0.618*(b-a);
f1=fun1(x1); f2=fun1(x2); k=0;
while (b-a) > epsilon
alpha1 = a + 0.382 * (b - a);    alpha2 = a + 0.618 * (b - a);
    if fun1(alpha1) < fun1(alpha2)
        b = alpha2;
    else
        a = alpha1;
    end
end

x=(b+a)/2;
result=fun1(x);
%*****
clc; clear all; x0=[-1,3];
fun1=@(x)x^2-5*x+4;
[k,x,result]=goldensearch(fun1,x0,1e-9)
```



Search algorithm

□ 一维搜索法-斐波那契法 (Fibonacci method)

斐波那契法不要求区间按比例缩短，而是按照斐波那契数列计算区间缩短比例，斐波那契数列满足如下关系：

$$F_n = F_{n-1} + F_{n-2}$$

其中 $F_0 = F_1 = 1$ 。该法中函数在区间 $[0,1]$ 上按如下点评估函数值

$$x_1 = \frac{F_{n-2}}{F_n}$$
$$x_2 = \frac{F_{n-1}}{F_n}$$

若 $f(x_1) \leq f(x_2)$ ，则极小点在区间 $[0, x_2] = \left[0, \frac{F_{n-1}}{F_n}\right]$ 内，若 $f(x_1) > f(x_2)$ ，则极小点在区间 $[x_1, 1] = \left[\frac{F_{n-2}}{F_n}, 1\right]$ 内。两种结果区间长度一致均为 $\frac{F_{n-1}}{F_n}$ ，第二种区间长度为 $1 - \frac{F_{n-2}}{F_n} = \frac{F_n - F_{n-2}}{F_n} = \frac{F_{n-1}}{F_n}$ 。



Search algorithm

□ 一维搜索法-斐波那契法 (Fibonacci method)

若为第一种情形，即极小点在 $\left[0, \frac{F_{n-1}}{F_n}\right]$ 内，与 x_1 比较的点为

$$x_3 = \frac{F_{n-3}}{F_{n-1}} * L = \frac{F_{n-3}}{F_{n-1}} * \frac{F_{n-1}}{F_n} = \frac{F_{n-3}}{F_n}$$
$$x_1 = \frac{F_{n-2}}{F_n} = \frac{F_{n-2}}{F_{n-1}} * \frac{F_{n-1}}{F_n}$$

第一次收缩后两个比较点取在与区间右端点的比值为 $\frac{F_{n-2}}{F_{n-1}}$ 及 $\frac{F_{n-3}}{F_{n-1}}$ 的位置。只需再算 x_3 处函数值，可将区间缩短为 $\left[0, \frac{F_{n-2}}{F_n}\right]$ 或 $\left[\frac{F_{n-3}}{F_n}, \frac{F_{n-1}}{F_n}\right]$ ，易算出区间长度为 $\frac{F_{n-2}}{F_n}$ 。若为第二种情形，即极小点在 $\left[\frac{F_{n-2}}{F_n}, 1\right]$ 内，与 x_2 比较的点为

$$x_3 = \frac{F_{n-2}}{F_n} + \frac{F_{n-2}}{F_{n-1}} \frac{F_{n-1}}{F_n} = \frac{2F_{n-2}}{F_n}$$
$$x_2 = \frac{F_{n-1}}{F_n} = \frac{F_{n-2} + F_{n-3}}{F_n} = \frac{F_{n-2}}{F_n} + \frac{F_{n-3}}{F_n} = \frac{F_{n-2}}{F_n} + \frac{F_{n-3}}{F_{n-1}} * \frac{F_{n-1}}{F_n}$$



Search algorithm

□ 一维搜索法-斐波那契法 (Fibonacci method)

可看出两个比较点在与区间右端点比值为 $\frac{F_{n-2}}{F_{n-1}}$ 及 $\frac{F_{n-3}}{F_{n-1}}$ 的位置。只需再算 x_3 处函数值, 可将区间缩短为 $\left[\frac{F_{n-1}}{F_n}, 1\right]$ 或者 $\left[\frac{F_{n-2}}{F_n}, \frac{2F_{n-2}}{F_n}\right]$, 容易算出区间长度均为 $\frac{F_{n-2}}{F_n}$ 。由此区间长度依次为 $1, \frac{F_{n-1}}{F_n}, \frac{F_{n-2}}{F_n}, \frac{F_{n-3}}{F_n}, \dots$ 。每个区间中两个比较点位置与区间右端点比值分别为:

$$\frac{F_{n-2}}{F_n} \text{ \& } \frac{F_{n-1}}{F_n}, \quad \frac{F_{n-3}}{F_{n-1}} \text{ \& } \frac{F_{n-2}}{F_{n-1}}, \quad \frac{F_{n-4}}{F_{n-2}} \text{ \& } \frac{F_{n-3}}{F_{n-2}}, \dots$$

计算 $n-1$ 次函数值后, 区间长度缩短为 $\frac{F_2}{F_n} = \frac{2}{F_n}$ 。若未给定计算函数值的次数, 只给定最后区间长为原区间长的 $\frac{1}{K}$, 根据给定近似极小点的精度要求确定计算次数, 即


$$\frac{1}{F_n} \leq \frac{1}{K}$$

计算得到 F_n , 由此可确定至少需要计算函数值的次数。

Search algorithm

□ 一维搜索法-斐波那契法 (Fibonacci method)

算法框图:





Search algorithm

□ 一维搜索法-斐波那契法 (Fibonacci method)

斐波那契法与黄金分割法计算过程类似，不同之处在于斐波那契法区间收缩率是变化的，且可预先给定计算函数值的次数。用归纳法可以证明，斐波那契数可表示为

$$F_n = \frac{1}{\sqrt{5}} \left[\left(\frac{1 + \sqrt{5}}{2} \right)^{n+1} - \left(\frac{1 - \sqrt{5}}{2} \right)^{n+1} \right]$$

由此可得

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{F_{n-1}}{F_n} &= \lim_{n \rightarrow \infty} \frac{\left(\frac{1 + \sqrt{5}}{2} \right)^n - \left(\frac{1 - \sqrt{5}}{2} \right)^n}{\left(\frac{1 + \sqrt{5}}{2} \right)^{n+1} - \left(\frac{1 - \sqrt{5}}{2} \right)^{n+1}} \\ &= \lim_{n \rightarrow \infty} 2 * \frac{(1 + \sqrt{5})^n - (1 - \sqrt{5})^n}{(1 + \sqrt{5})^{n+1} - (1 - \sqrt{5})^{n+1}} = \frac{2}{1 + \sqrt{5}} \approx 0.618 \end{aligned}$$

由此可见斐波那契法的极限情况就是黄金分割法。



Search algorithm

□ 一维搜索法-斐波那契法 (Fibonacci method)

Code:

```
function [k,x,result]=Fibonacci(fun1,interval,epsilon)
a=interval(1);  b=interval(2);  F=[1 1];          n=3;
while F(end)<(b-a)/epsilon;
    F(n)=F(n-1)+F(n-2);          n=n+1;
end
n=n-1;  x1=a+(F(n-2)/F(n))*(b-a);          x2=a+(F(n-1)/F(n))*(b-a);
f1=fun1(x1);  f2=fun1(x2);  k=0;
while n>3
    k=k+1;  n=n-1;
    if f1>f2
        a=x1;  x1=x2;  f1=f2;  x2=a+(F(n-1)/F(n))*(b-a);  f2=fun1(x2);
    elseif f1==f2
        a=x1; b=x2; x1=a+(F(n-2)/F(n))*(b-a); x2=a+(F(n-1)/F(n))*(b-a);
    else
        b=x2;  x2=x1;  f2=f1;  x1=a+(F(n-2)/F(n))*(b-a);
    end
    f1=fun1(x1);
end
end
x=(a+b)/2;  result=fun1(x);
```



Optimization algorithm

□ 牛顿法

区间 $[a_0, b_0]$ 内函数 $f(x)$ 为单峰函数，且二阶连续可微。假定 $f(x)$ 的极小点为 $x^{(k)}$ ，那么在点 $x^{(k)}$ 处用Taylor级数展开，取到二阶项，有

$$\varphi(x) = f(x^{(k)}) + f'(x^{(k)})(x - x^{(k)}) + \frac{1}{2}f''(x^{(k)})(x - x^{(k)})^2$$

该函数在点 $x^{(k)}$ 处与函数 $f(x)$ 函数值相同、一阶及二阶导数值相同。

根据极值条件，令 $\varphi'(x) = 0$ ，则

$$\varphi'(x) = f'(x^{(k)}) + f''(x^{(k)})(x - x^{(k)}) = 0$$

可得该近似表达式的极值点为

$$x = x^{(k+1)} = x^{(k)} - \frac{f'(x^{(k)})}{f''(x^{(k)})}$$

Optimization algorithm


□ 牛顿法

若求得的 $x^{(k+1)}$ 满足：

$$|f'(x^{(k+1)})| < \varepsilon$$

则可认为 $x^{(k+1)}$ 为 $f(x)$ 的极小点，其中 ε 为事先给定的精度，若不满足，则继续迭代。

✓ 算法框图





Optimization algorithm


□ 牛顿法-几何意义

将 $\varphi'(x) = f'(x^{(k)}) + f''(x^{(k)})(x - x^{(k)}) = 0$ 改写为

$$f''(x^{(k)}) = \frac{f'(x^{(k)})}{x^{(k)} - x^{(k+1)}}$$

该式代表过曲线 $f'(x)$ 上 $(x^{(k)}, f'(x^{(k)}))$ 点切线的斜率 (即 $f''(x^{(k)})$) , $x^{(k+1)}$ 刚好是该切线与横坐标的交点。

牛顿法的优点为收敛速度快, 其缺点是需计算一、二阶导数, 因此适应性欠缺。此外, 当 $f'(x)$ 在搜索区间上曲线弯曲复杂时易导致搜索失败。





Optimization algorithm

□ 牛顿法

Case 1: Newton's method求 $\min f(x) = \int_0^x \arctan t \, dt$, 取 $x^0 = 1, \varepsilon = 0.01$.

Solution: $f'(x) = \arctan x, f''(x) = \frac{1}{1+x^2}$,

k	x^k	$f'(x^k)$	$1/f''(x^k)$	ε	x^{k+1}
0	1	0.7854	2	0.7854	-0.5708
1	-0.5708	-0.5187	1.3258	-0.5187	0.1169
2	0.1169	0.1164	1.0137	0.1164	-0.0011
3	-0.0011	-0.0011			



Optimization algorithm

□ 牛顿法 (多元函数)

优化问题

$$\min f(\mathbf{x}), \mathbf{x} \in R^n$$

其中 $f(\mathbf{x})$ 在点 $\mathbf{x}^{(k)}$ 处具有二阶连续偏导, Hessian矩阵 $\nabla^2 f(\mathbf{x}^{(k)})$ 正定。

已有 $f(\mathbf{x})$ 在极小点的第 k 阶估计值 $\mathbf{x}^{(k)}$, 并将 $f(\mathbf{x})$ 二阶Taylor展开:

$$f(\mathbf{x}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)}) + o(\|\mathbf{x} - \mathbf{x}^{(k)}\|^2)$$

上式主要部分为

$$Q(\mathbf{x}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$$

在 $\mathbf{x}^{(k)}$ 附近可用 $Q(\mathbf{x})$ 近似 $f(\mathbf{x})$, $Q(\mathbf{x}) \approx f(\mathbf{x})$, 故可用 $Q(\mathbf{x})$ 极小点来近似 $f(\mathbf{x})$ 的极小点, 求 $Q(\mathbf{x})$ 的驻点

$$\nabla Q(\mathbf{x}) = \nabla f(\mathbf{x}^{(k)}) + \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$$



Optimization algorithm

□ 牛顿法 (多元函数)

由 $\nabla Q(\mathbf{x}) = 0$ 得 $Q(\mathbf{x})$ 的平稳点 $\mathbf{x}^{(k+1)}$

$$\nabla f(\mathbf{x}^{(k)}) + \nabla^2 f(\mathbf{x}^{(k)})(\mathbf{x} - \mathbf{x}^{(k)}) = 0$$

$$\mathbf{x} - \mathbf{x}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$$

$$\therefore \mathbf{x}^{k+1} = \mathbf{x}^k - [\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)}) \quad (*)$$

基本迭代格式

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \lambda_k \mathbf{p}^k$$

$$\mathbf{p}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)}), \lambda_k = 1$$

$\mathbf{p}^k$ 为牛顿方向, λ_k 为牛顿步长。



Optimization algorithm

□ 牛顿法（多元函数）基本步骤

- S.1 选取初始数据：初始点 $\mathbf{x}^{(0)}$ ，终止条件 $\varepsilon > 0$ ， $k = 0$
- S.2 求梯度向量 $\nabla f(\mathbf{x}^{(k)})$ ，并计算 $\|\nabla f(\mathbf{x}^{(k)})\|$ ，若 $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon$ ，停止迭代，并输出 $\mathbf{x}^{(k)}$ ，否则转入下一步
- S.3 构造牛顿方向
$$\mathbf{p}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$$
- S.4 迭代算法：计算 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{p}^{(k)}$ ，以 $\mathbf{x}^{(k+1)}$ 作为下一轮迭代点， $k = k + 1$ ，转入第二步S.2



Optimization algorithm

□ 牛顿法

Case 2: Newton's method求函数 $\min f(x) = x_1^2 + 25x_2^2$, 取 $x^0 = (2,2)^T, \varepsilon = 0.000001$.

Solution: (1) 求梯度和Hessian矩阵

$$\nabla f(x) = \begin{bmatrix} 2x_1 \\ 50x_2 \end{bmatrix}, \nabla^2 f(x) = \begin{bmatrix} 2 & 0 \\ 0 & 50 \end{bmatrix}$$

$$\therefore \nabla f(x^0) = \begin{bmatrix} 4 \\ 100 \end{bmatrix}, \text{ and } \nabla^2 f(x^0) = \begin{bmatrix} 2 & 0 \\ 0 & 50 \end{bmatrix} \text{ is positive definition}$$

$$\therefore [\nabla^2 f(x^0)]^{-1} = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{50} \end{bmatrix}$$

(2) 确定牛顿方向

$$p^{(0)} = -[\nabla^2 f(x^{(0)})]^{-1} \nabla f(x^{(0)}) = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.02 \end{bmatrix} \begin{bmatrix} 4 \\ 100 \end{bmatrix} = \begin{bmatrix} -2 \\ -2 \end{bmatrix}$$

$$\therefore x^{(1)} = x^{(0)} + p^{(0)} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} -2 \\ -2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$



Optimization algorithm

□ 牛顿法

Case 2: Newton's method求函数 $\min f(x) = x_1^2 + 25x_2^2$, 取 $x^0 = (2, 2)^T$, $\varepsilon = 0.000001$.

相应的梯度为 $\nabla f(x^{(1)}) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, 且 $\|\nabla f(x^{(1)})\| < \varepsilon$, 故算法终止, 即

$$x^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

是所求的最小点。

Newton's method在极小点附近收敛性很好, 速度快。但Newton's method要求初始点离最优解不远, 若初始点离最优点太远并不能保证其收敛, 甚至不是下降方向。为了克服Newton's method的缺点, 人们保留从Newton's method中选取牛顿方向作为搜索方向, 摒弃其步长恒取1的做法, 从而用一维搜索确定最优步长来构造算法, 通常称为修正牛顿法。



Optimization algorithm

□ 修正牛顿法

基本步骤

- S.1 选取初始数据：初始点 $\mathbf{x}^{(0)}$ ，终止条件 $\varepsilon > 0$ ， $k = 0$
- S.2 求梯度向量 $\nabla f(\mathbf{x}^{(k)})$ ，并计算 $\|\nabla f(\mathbf{x}^{(k)})\|$ ，若 $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon$ ，停止迭代，并输出 $\mathbf{x}^{(k)}$ ，否则转入下一步
- S.3 构造牛顿方向

$$\mathbf{p}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$$

- S.4 进行一维搜索，求 λ_k 使

$$f(\mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}) = \min_{\lambda \geq 0} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}), \quad \lambda \geq 0$$

令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}$ ， $k = k + 1$ ，转入S.2步



Optimization algorithm

修正牛顿法

Case 3: 修正牛顿法求函数 $\min f(\mathbf{x}) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2$, 取 $\mathbf{x}^0 = (0,0)^T$, $\varepsilon = 0.000001$.

Solution: (1) 求梯度和Hessian矩阵

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 1 + 4x_1 + 2x_2 \\ -1 + 2x_1 + 2x_2 \end{bmatrix}, \nabla^2 f(\mathbf{x}) = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}$$

$$\therefore \nabla f(\mathbf{x}^0) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \text{ and } \nabla^2 f(\mathbf{x}^0) = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix} \text{ is positive definition}$$

$$\therefore [\nabla^2 f(\mathbf{x}^0)]^{-1} = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{50} \end{bmatrix}$$

(2) 确定牛顿方向

$$\mathbf{p}^{(0)} = -[\nabla^2 f(\mathbf{x}^{(0)})]^{-1} \nabla f(\mathbf{x}^{(0)}) = -\begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 1.5 \end{bmatrix}$$



Optimization algorithm

修正牛顿法

Case 3: 修正牛顿法求函数 $\min f(\mathbf{x}) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2$,
取 $\mathbf{x}^0 = (0,0)^T$, $\varepsilon = 0.000001$.

Solution: (3) 沿牛顿方向作一维搜索

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \lambda \mathbf{p}^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \lambda \begin{bmatrix} -1 \\ 1.5 \end{bmatrix} = \begin{bmatrix} -\lambda \\ 1.5\lambda \end{bmatrix}$$

则 $f(\mathbf{x}^{(0)} + \lambda \mathbf{p}^{(0)}) = -\lambda - 1.5\lambda + 2\lambda^2 - 3\lambda^2 + 2.25\lambda^2 = 1.25\lambda^2 - 2.5\lambda$, 因此最优步长为 $\lambda_0 = 1$

$$\therefore \mathbf{x}^{(1)} = \begin{bmatrix} -1 \\ 1.5 \end{bmatrix}$$

(4) 计算新迭代点处的梯度 $\nabla f(\mathbf{x}^{(1)})$

$$\nabla f(\mathbf{x}^{(1)}) = \begin{bmatrix} 1 + 4x_1 + 2x_2 \\ -1 + 2x_1 + 2x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\therefore \|\nabla f(\mathbf{x}^{(1)})\| = 0 < \varepsilon \rightarrow stop$$

即 $\mathbf{x}^{(1)}$ 为所求的极小点。



Optimization algorithm

□ 修正牛顿法

修正牛顿法虽然比牛顿法有改进，但也有不足之处：(1) 要计算 Hessian 矩阵及其逆矩阵，工作量大；(2) 要求迭代点 $\mathbf{x}^{(k)}$ 处的 Hessian 矩阵正定，有时候函数未必能满足，因而导致牛顿方向未必是下降方向，也有一些函数的 Hessian 矩阵不可逆，因此不能确定出后继点，这些均是修正牛顿法与牛顿法的局限性。



Optimization algorithm

□ 最速下降法

最速下降法又称为梯度法，是许多非线性算法的一个基础。优化问题：

$$\min f(\mathbf{x}), \mathbf{x} \in R^n, f(\mathbf{x}) \in R^1$$

式中 $f(\mathbf{x})$ 具有一阶连续偏导，有极小点 $\mathbf{x}^*$ ，若现已求得 $\mathbf{x}^*$ 的第 k 次近似值 $\mathbf{x}^{(k)}$ ，欲求得第 $k+1$ 次近似值 $\mathbf{x}^{(k+1)}$ ，需要确定搜索方向 $\mathbf{p}^{(k)}$ 。

设 $\mathbf{x} = \mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}$ ，将 $f(\mathbf{x})$ 在 $\mathbf{x}^{(k)}$ 点处作一阶Taylor展开

$$f(\mathbf{x}) = f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}) = f(\mathbf{x}^{(k)}) + \lambda [\nabla f(\mathbf{x}^{(k)})]^T \mathbf{p}^{(k)} + O(\|\lambda \mathbf{p}^{(k)}\|)$$

其中 $O(\|\lambda \mathbf{p}^{(k)}\|) = O(\|\lambda\|)$ 是比 λ 高阶的无穷小量，而 $\|\mathbf{p}^{(k)}\| = 1$



Optimization algorithm

□ 最速下降法

若忽略高阶无穷小量，则

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(k)}) + \lambda [\nabla f(\mathbf{x}^{(k)})]^T \mathbf{p}^{(k)}$$

$$f(\mathbf{x}) - f(\mathbf{x}^{(k)}) \approx \lambda [\nabla f(\mathbf{x}^{(k)})]^T \mathbf{p}^{(k)}$$

$$\therefore f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)}) \approx \lambda [\nabla f(\mathbf{x}^{(k)})]^T \mathbf{p}^{(k)} \quad (*)$$

若求最小值的优化问题，则需要 $f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)}) \leq 0$ ，那么

$$\lambda [\nabla f(\mathbf{x}^{(k)})]^T \mathbf{p}^{(k)} \leq 0, \lambda > 0$$

如何选取搜索方向使得目标函数值下降最快？

$$[\nabla f(\mathbf{x}^{(k)})]^T \mathbf{p}^{(k)} = \|\nabla f(\mathbf{x}^{(k)})\| \|\mathbf{p}^{(k)}\| \cos \theta$$



Optimization algorithm

□ 最速下降法

$$[\nabla f(\mathbf{x}^{(k)})]^T \mathbf{p}^{(k)} = \|\nabla f(\mathbf{x}^{(k)})\| \|\mathbf{p}^{(k)}\| \cos\theta$$

其中 θ 为向量 $\nabla f(\mathbf{x}^{(k)})$ 与向量 $\mathbf{p}^{(k)}$ 之间的夹角，那么也就是说只有当 $\cos\theta < 0$ 时， $[\nabla f(\mathbf{x}^{(k)})]^T \mathbf{p}^{(k)}$ 才会出现负值，才能使得函数值下降。显然只有当 $\theta = 180^\circ$ 时目标函数值下降最快，故 $\mathbf{p}^{(k)}$ 与 $-\nabla f(\mathbf{x}^{(k)})$ 方向一致，即 $\mathbf{p}^{(k)}$ 为梯度的负方向。且可以采用

$$\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$$

因此该法叫做梯度下降或者最速下降法。



Optimization algorithm

□ 最速下降法

算法步骤:

➤ S.1 给定初始数据: 初始点 $\mathbf{x}^{(0)}$, 终止条件 $\varepsilon > 0$, $k = 0$

➤ S.2 求梯度向量范数或模的值 $\|\nabla f(\mathbf{x}^{(k)})\|$:

✓ 若 $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon$, 停止迭代, 并输出 $\mathbf{x}^{(k)}$ 作为极小点的近似值

✓ 若 $\|\nabla f(\mathbf{x}^{(k)})\| > \varepsilon$, 转入下一步

➤ S.3 构造负梯度方向

$$\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$$

➤ S.4 进行一维搜索, 求 λ_k 后, 令

$$\begin{aligned}\mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \\ k &= k + 1\end{aligned}$$

转入S.2步



Optimization algorithm

□ 最速下降法--最优步长的简单计算

对于一些简单函数，可以通过直接求导获得最优步长因子，当优化算法为最速下降法时，搜索方向即为最速下降方向($-\nabla f(\mathbf{x}^{(k)})$)时，以 $\mathbf{x}^{(k)}$ 为起点的最优步长公式为：

$$\lambda_k = \frac{[\nabla f(\mathbf{x}^{(k)})]^T \nabla f(\mathbf{x}^{(k)})}{[\nabla f(\mathbf{x}^{(k)})]^T H(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)})} \quad (**)$$

设 $f(\mathbf{x})$ 具有二阶连续偏导，将函数在点 $\mathbf{x}^{(k)}$ 处作二阶Taylor展开

$$\begin{aligned} & f(\mathbf{x}^{(k)} - \lambda \nabla f(\mathbf{x}^{(k)})) \\ &= f(\mathbf{x}^{(k)}) + [\nabla f(\mathbf{x}^{(k)})]^T [-\lambda \nabla f(\mathbf{x}^{(k)})] \\ &+ \frac{1}{2} [-\lambda \nabla f(\mathbf{x}^{(k)})]^T H(\mathbf{x}^{(k)}) [-\lambda \nabla f(\mathbf{x}^{(k)})] + O\|\lambda \nabla f(\mathbf{x}^{(k)})\|^2 \end{aligned}$$

上式主要部分记为 $H(\lambda)$

$$H(\lambda) = f(\mathbf{x}^{(k)}) - \lambda [\nabla f(\mathbf{x}^{(k)})]^T \nabla f(\mathbf{x}^{(k)}) + \frac{1}{2} \lambda^2 [\nabla f(\mathbf{x}^{(k)})]^T H(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)})$$



Optimization algorithm

□ 最速下降法--最优步长的简单计算

$$H(\lambda) = f(\mathbf{x}^{(k)}) - \lambda [\nabla f(\mathbf{x}^{(k)})]^T \nabla f(\mathbf{x}^{(k)}) + \frac{1}{2} \lambda^2 [\nabla f(\mathbf{x}^{(k)})]^T H(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)})$$

函数 $H(\lambda)$ 为 λ 的一元二次函数，且其开口向上，因此该函数的唯一极值点即为(**)式中的最优步长，即可得到

$$\lambda_k = \frac{[\nabla f(\mathbf{x}^{(k)})]^T \nabla f(\mathbf{x}^{(k)})}{[\nabla f(\mathbf{x}^{(k)})]^T H(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)})}$$



Optimization algorithm

□ 最速下降法--Case

试用最速下降法求下述函数极小点, $f(\mathbf{x}) = (x_1 - 1)^2 + (x_2 - 1)^2$

初始点 $\mathbf{x}^{(0)} = (0,0)^T, \varepsilon = 0.01$

Solution: (1) 梯度向量的模或者范数

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 - 2 \\ 2x_2 - 2 \end{bmatrix}, \mathbf{x}^{(0)} = (0,0)^T, \nabla f(\mathbf{x}^{(0)}) = \begin{bmatrix} -2 \\ -2 \end{bmatrix}$$

且

$$\|\nabla f(\mathbf{x}^{(0)})\| = \sqrt{8} > \varepsilon$$

(2) 构造负梯度方向

$$\mathbf{p}^{(0)} = -\nabla f(\mathbf{x}^{(0)}) = -\begin{bmatrix} -2 \\ -2 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

(3) 进行一维搜索



Optimization algorithm

□ 最速下降法--Case

试用最速下降法求下述函数极小点, $f(\mathbf{x}) = (x_1 - 1)^2 + (x_2 - 1)^2$

初始点 $\mathbf{x}^{(0)} = (0,0)^T, \varepsilon = 0.01$

(3) 进行一维搜索

Hessian矩阵

$$H(\mathbf{x}^{(0)}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

最优步长

$$\begin{aligned} \lambda_0 &= \frac{[\nabla f(\mathbf{x}^{(0)})]^T \nabla f(\mathbf{x}^{(0)})}{[\nabla f(\mathbf{x}^{(0)})]^T H(\mathbf{x}^{(0)}) \nabla f(\mathbf{x}^{(0)})} = \frac{[-2, -2] \begin{bmatrix} -2 \\ -2 \end{bmatrix}}{[-2, -2] \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} -2 \\ -2 \end{bmatrix}} \\ &= \frac{8}{[-4, -4] \begin{bmatrix} -2 \\ -2 \end{bmatrix}} = \frac{8}{16} = \frac{1}{2} \end{aligned}$$



Optimization algorithm

□ 最速下降法--Case

试用最速下降法求下述函数极小点, $f(\mathbf{x}) = (x_1 - 1)^2 + (x_2 - 1)^2$

初始点 $\mathbf{x}^{(0)} = (0,0)^T, \varepsilon = 0.01$

(3) 进行一维搜索

因此下一个近似点

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \lambda_0 \mathbf{p}^{(0)} = \mathbf{x}^{(0)} + \lambda_0 [-\nabla f(\mathbf{x}^{(0)})] = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\therefore \nabla f(\mathbf{x}^{(1)}) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\|\nabla f(\mathbf{x}^{(1)})\| = 0 < \varepsilon = 0.01$$

即 $f(\mathbf{x})$ 的极小点位 $\mathbf{x}^* = \mathbf{x}^{(1)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$



Optimization algorithm

□ 最速下降法

- 最速下降法对初始点的选择要求不高，每一轮迭代工作量较少，它可以比较快的从初始点达到极小点附近，但是接近极小点时，最速下降法会出现锯齿现象，迭代产生的点形成之字形，每次迭代移动步长很小，收敛速度很慢。
- 因此常常将梯度法与其它方法结合起来使用，比如与牛顿法结合，前期采用最速下降法，接近极小点时改用牛顿法。



Optimization algorithm

□ 变量轮换法—基本思想

变量轮换法是把多变量函数的优化问题转化为一系列单变量函数的优化问题来求解。认为有利的搜索方向是各坐标轴的方向，因此轮流按照各坐标轴的方向搜索最优点。

具体为从某一个给定点出发，按第 i 各坐标轴 x_i 的方向搜索时，在所有的变量中(n 个变量)，只有单个变量 x_i 在变化，其余 $n-1$ 个变量都取给定点的值保持不变，依次从 x_1 到 x_n 做 n 次单变量的一维搜索，完成变量轮换法的依次迭代。



Optimization algorithm

□ 变量轮换法

基本步骤（针对 $\min f(\mathbf{x})$ 优化问题）

- S.1 给定初始数据：初始点 $\mathbf{x}^{(1)} \in R^n$
- S.2 从 $\mathbf{x}^{(1)}$ 出发，先沿第一个坐标轴的方向 e_1 进行一维搜索，记求得的最优步长为 λ_1 ，则可得到新点 $\mathbf{x}^{(2)}$

$$\begin{cases} \mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 e_1 \\ f(\mathbf{x}^{(2)}) = f(\mathbf{x}^{(1)} + \lambda_1 e_1) = \min_{\lambda} f(\mathbf{x}^{(1)} + \lambda e_1) \end{cases}$$

再以 $\mathbf{x}^{(2)}$ 为起点，沿第2个坐标轴的方向 e_2 进行一维搜索，求得的最优步长为 λ_2 ，则可得到新点 $\mathbf{x}^{(3)}$

$$\begin{cases} \mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 e_2 \\ f(\mathbf{x}^{(3)}) = f(\mathbf{x}^{(2)} + \lambda_2 e_2) = \min_{\lambda} f(\mathbf{x}^{(2)} + \lambda e_2) \end{cases}$$



Optimization algorithm

□ 变量轮换法

基本步骤（针对 $\min f(\mathbf{x})$ 优化问题）

如此依次沿各坐标轴方向进行一维搜索，直到 n 个坐标轴方向全部搜索一遍，最后可得到点 $\mathbf{x}^{(n+1)}$

$$\begin{cases} \mathbf{x}^{(n+1)} = \mathbf{x}^{(n)} + \lambda_n \mathbf{e}_n \\ f(\mathbf{x}^{(n+1)}) = f(\mathbf{x}^{(n)} + \lambda_n \mathbf{e}_n) = \min_{\lambda} f(\mathbf{x}^{(n)} + \lambda \mathbf{e}_n) \end{cases}$$

从初始点 $\mathbf{x}^{(1)}$ 出发，经过上述 n 个坐标轴方向的一维搜索得到点 $\mathbf{x}^{(n+1)}$ ，即完成了变量轮换法的依次迭代。

➤ S.3 令 $\mathbf{x}^{(1)} = \mathbf{x}^{(n+1)}$ ，返回S.2步，即以 $\mathbf{x}^{(n+1)}$ 点为起点，再沿各坐标轴方向依次进行一维搜索，直到所得到最新点 $\mathbf{x}^{(n+1)}$ 满足所给定的精度为止，输出 $\mathbf{x}^{(n+1)}$ 作为 $f(\mathbf{x})$ 极小点的近似值。



Optimization algorithm

□ 变量轮换法--Case

用变量轮换法求解 $\min f(\mathbf{x}) = 3x_1^2 + 2x_2^2 + x_3^2$, 已知初始点 $\mathbf{x}^{(1)} = (1, 2, 3)^T$, 当 $\|\mathbf{x}^{(n+1)} - \mathbf{x}^{(1)}\| < 0.01$ 时停止迭代。

Solution: (1) 首先从初始点 $\mathbf{x}^{(1)}$ 出发, 沿 x_1 轴方向 e_1 进行一维搜索:

$$\mathbf{x}^{(1)} + \lambda e_1 = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} + \lambda \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 + \lambda \\ 2 \\ 3 \end{bmatrix}$$

$$f(\mathbf{x}^{(1)} + \lambda e_1) = 3(1 + \lambda)^2 + 2 * 2^2 + 3^2 = 3(1 + \lambda)^2 + 17 = \varphi_1(\lambda)$$

$$\varphi_1'(\lambda) = 6\lambda + 6 = 0, \lambda_1 = -1$$



Optimization algorithm

□ 变量轮换法--Case

用变量轮换法求解 $\min f(\mathbf{x}) = 3x_1^2 + 2x_2^2 + x_3^2$, 已知初始点 $\mathbf{x}^{(1)} = (1, 2, 3)^T$, 当 $\|\mathbf{x}^{(n+1)} - \mathbf{x}^{(1)}\| < 0.01$ 时停止迭代。

Solution:

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{e}_1 = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} + (-1) * \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \\ 3 \end{bmatrix}$$

(2) 再从 $\mathbf{x}^{(2)}$ 点出发, 沿 x_2 轴方向 $\mathbf{e}_2$ 进行一维搜索:

$$\mathbf{x}^{(2)} + \lambda \mathbf{e}_2 = \begin{bmatrix} 0 \\ 2 \\ 3 \end{bmatrix} + \lambda \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 + \lambda \\ 3 \end{bmatrix}$$

$$f(\mathbf{x}^{(2)} + \lambda \mathbf{e}_2) = 2 * (2 + \lambda)^2 + 3^2 = 2(2 + \lambda)^2 + 9 = \varphi_2(\lambda)$$

$$\therefore \lambda_2 = -2$$



Optimization algorithm

□ 变量轮换法--Case

用变量轮换法求解 $\min f(\mathbf{x}) = 3x_1^2 + 2x_2^2 + x_3^2$, 已知初始点 $\mathbf{x}^{(1)} = (1, 2, 3)^T$, 当 $\|\mathbf{x}^{(n+1)} - \mathbf{x}^{(1)}\| < 0.01$ 时停止迭代。

Solution:

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{e}_2 = \begin{bmatrix} 0 \\ 2 \\ 3 \end{bmatrix} + (-2) * \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix}$$

(3) 再从 $\mathbf{x}^{(3)}$ 点出发, 沿 x_3 轴方向 $\mathbf{e}_3$ 进行一维搜索:

$$\mathbf{x}^{(3)} + \lambda \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix} + \lambda \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 3 + \lambda \end{bmatrix}$$

$$f(\mathbf{x}^{(3)} + \lambda \mathbf{e}_3) = (3 + \lambda)^2 = \varphi_3(\lambda)$$

$$\therefore \lambda_3 = -3$$



Optimization algorithm

□ 变量轮换法--Case

用变量轮换法求解 $\min f(\mathbf{x}) = 3x_1^2 + 2x_2^2 + x_3^2$, 已知初始点 $\mathbf{x}^{(1)} = (1, 2, 3)^T$, 当 $\|\mathbf{x}^{(n+1)} - \mathbf{x}^{(1)}\| < 0.01$ 时停止迭代。

Solution:

$$\mathbf{x}^{(4)} = \mathbf{x}^{(3)} + \lambda_3 \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix} + (-3) * \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\because \|\mathbf{x}^{(1)} - \mathbf{x}^{(4)}\| = \sqrt{14} > 0.01$$

因此将 $\mathbf{x}^{(4)} \rightarrow \mathbf{x}^{(1)}$ 再进行新一轮迭代。

(4) 重新从点 $\mathbf{x}^{(1)}$ 出发, 沿 x_1 轴方向 $\mathbf{e}_1$ 进行一维搜索:

$$\mathbf{x}^{(1)} + \lambda \mathbf{e}_1 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} + \lambda \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} \lambda \\ 0 \\ 0 \end{bmatrix}$$



Optimization algorithm

□ 变量轮换法--Case

$$\mathbf{x}^{(1)} + \lambda e_1 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} + \lambda \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} \lambda \\ 0 \\ 0 \end{bmatrix}$$

$$f(\mathbf{x}^{(1)} + \lambda e_1) = 3\lambda^2 = \varphi_1(\lambda)$$

$$\therefore \lambda_1 = 0$$

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 e_1 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} + 0 * \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

(5) 从点 $\mathbf{x}^{(2)}$ 出发, 沿 x_2 轴方向 e_2 进行一维搜索:

$$\mathbf{x}^{(2)} + \lambda e_2 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} + \lambda \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ \lambda \\ 0 \end{bmatrix}$$

$$f(\mathbf{x}^{(2)} + \lambda e_2) = 2\lambda^2 = \varphi_2(\lambda)$$

$$\therefore \lambda_2 = 0$$

$$\mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 e_2 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} + 0 * \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$



Optimization algorithm

□ 变量轮换法--Case

(5) 从点 $\mathbf{x}^{(3)}$ 出发, 沿 x_3 轴方向 e_3 进行一维搜索:

$$\mathbf{x}^{(3)} + \lambda e_3 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} + \lambda \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \lambda \end{bmatrix}$$

$$f(\mathbf{x}^{(3)} + \lambda e_3) = \lambda^2 = \varphi_3(\lambda)$$

$$\therefore \lambda_3 = 0$$

$$\mathbf{x}^{(4)} = \mathbf{x}^{(3)} + \lambda_3 e_3 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} + 0 * \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\therefore \|\mathbf{x}^{(1)} - \mathbf{x}^{(4)}\| = 0 < 0.01, stop$$

所以 $\mathbf{x}^{(4)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$ 为极小点。



Optimization algorithm

□ 变量轮换法

变量轮换法的缺点：

收敛速度慢

搜索效率低

优点：

思路清晰、简单

沿各坐标轴方向进行搜索



Linear Programming

□ 数学模型

约束条件和目标函数都是决策变量的线性函数的规划问题称为线性规划：

$$\begin{aligned} \max(\min) \quad & z = c_1x_1 + c_2x_2 + \cdots + c_nx_n \\ \text{s.t.} \quad & a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \leq (= \text{ or } \geq) b_1 \\ & a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \leq (= \text{ or } \geq) b_2 \\ & \dots\dots\dots \\ & a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n \leq (= \text{ or } \geq) b_m \\ & x_1, x_2, \dots, x_n \geq 0 \end{aligned}$$

模型中 $x_1, x_2, \dots, x_n$ 通常称为决策变量； $c_1, c_2, \dots, c_n$ 称为价值系数；

$a_{11}, a_{12}, \dots, a_{mn}$ 为消耗系数； $b_1, b_2, \dots, b_m$ 为资源限制系数。



Linear Programming

➤ 标准型

$$\begin{aligned} \min z &= c_1x_1 + c_2x_2 + \cdots + c_nx_n \\ \text{s.t. } a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\dots\dots\dots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &= b_m \\ x_1, x_2, \cdots, x_n &\geq 0 \end{aligned}$$

➤ 矩阵形式

$$\begin{aligned} \min z &= \mathbf{c}\mathbf{x} \\ \text{s.t. } \mathbf{A}\mathbf{x} &= \mathbf{b} \\ \mathbf{x} &\geq 0 \end{aligned}$$

$$\mathbf{c} = (c_1, c_2, \cdots, c_n), \mathbf{x} = (x_1, x_2, \cdots, x_n)^T, \mathbf{b} = (b_1, b_2, \cdots, b_m)^T$$

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$



Linear Programming

► 向量形式

$$\min z = \mathbf{c}\mathbf{x}$$

$$s. t. \sum_{j=1}^n \mathbf{p}_j x_j = \mathbf{b}$$

$$\mathbf{x} \geq 0$$

$$\mathbf{c} = (c_1, c_2, \dots, c_n), \mathbf{x} = (x_1, x_2, \dots, x_n)^T, \mathbf{b} = (b_1, b_2, \dots, b_m)^T$$

$$\mathbf{p}_j = (a_{1j}, a_{2j}, \dots, a_{mj})^T$$

$$\mathbf{A} = (\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_n)$$



Linear Programming

➤非标准形式转化为标准形式

(1) 若目标函数为最大化: $\max z = \mathbf{c}\mathbf{x}$, 则作函数 $z' = -\mathbf{c}\mathbf{x}$, 然后对 z' 求最小化, 即 $\min z' = -\mathbf{c}\mathbf{x}$

(2) 若约束条件为小于等于型, 则在约束不等式左边加上一个新非负变量, 称为松弛变量, 将不等式改为等式

$$x_1 - 2x_2 + x_3 \leq 8 \rightarrow x_1 - 2x_2 + x_3 + x_4 = 8$$

$$x_4 \geq 0$$

(3) 若约束条件为大于等于型, 则在约束不等式左边减去一个新非负变量, 称为剩余变量, 将不等式改为等式

$$x_1 - 2x_2 + x_3 \leq 8 \rightarrow x_1 - 2x_2 + x_3 - x_4 = 8$$

$$x_4 \geq 0$$



Linear Programming

➤ 非标准形式转化为标准形式

(4) 若约束条件右端项 $b_i < 0$ ，则在约束不等式两端乘以-1，不等式改变方向，然后再将不等式转化为等式

(5) 若决策变量 x_k 无非负约束要求，即 x_k 可正可负，则可令两个新变量 $x'_k \geq 0$ ， $x''_k \geq 0$ ，然后 $x_k = x'_k - x''_k$ ，原有的数学模型中， x_k 均用 $x'_k - x''_k$ 替代，非负约束中增加 $x'_k \geq 0$ ， $x''_k \geq 0$

例 将下列线性规划问题转化为标准型

$$\max z = x_1 - 2x_2 + 3x_3$$

$$x_1 + x_2 + x_3 \leq 7$$

$$x_1 - x_2 + x_3 \geq 2$$

$$-3x_1 + x_2 + 2x_3 = -5$$

$$x_1 \leq 0, x_2 \geq 0, x_3 \text{ 无约束}$$



Simplex Method

- ✓ 线性规划问题可行域是一个有界或无界的凸多边形，其顶点个数为有限个
- ✓ 若线性规划问题有最优解，其最优解必可在某顶点上达到
容易想到找出所有基本可行解，然后逐个比较，求出最优解。但随着变量数和约束条件增加，基本可行解个数迅速增大，基本可行解可能有 C_n^m 个，若 $n=40, m=20$ 则 $C_{40}^{20} \approx 1.3 \times 10^{11}$
- ✓ 换一种思路：若从某一基本可行解(初始基本可行解)出发，每次寻求比上一个更好的基本可行解，而不比上一个号的基本可行解不去计算，可大大减少计算量。



Simplex Method

□ 基本思路

- ✓ 如何得到一个初始基本可行解
- ✓ 如何判别当前基本可行解是否已达到最优解
- ✓ 若当前解不是最优解，如何寻找一个更好的基本可行解

例题 说明单纯形法的基本思路

$$\begin{aligned}\max z &= 5x_1 + 2x_2 \\ s.t. \quad &30x_1 + 20x_2 \leq 160 \\ &5x_1 + x_2 \leq 15 \\ &x_1 \leq 4 \\ &x_1, x_2 \geq 0\end{aligned}$$



Simplex Method

□基本思路

例题 约束条件转化得到

$$\max z = 5x_1 + 2x_2 + 0 * x_3 + 0 * x_4 + 0 * x_5$$

$$s. t. 30x_1 + 20x_2 + x_3 = 160$$

$$5x_1 + x_2 + x_4 = 15$$

$$x_1 + x_5 = 4$$

$$x_1, x_2, x_3, x_4, x_5 \geq 0$$

消耗系数

$$A = \begin{bmatrix} 30 & 20 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix}$$



Simplex Method

$$A = \begin{bmatrix} 30 & 20 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix}$$

Step 1: 选择初始基矩阵 $B^{(0)} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$, 则对应的 $x_B = \begin{bmatrix} x_3 \\ x_4 \\ x_5 \end{bmatrix}$ 为

基变量, $x_N = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ 为非基变量, 初始基本可行解 $\begin{bmatrix} x_B \\ x_N \end{bmatrix} = \begin{bmatrix} B^{-1}b \\ 0 \end{bmatrix}$

经过计算初始基本可行解为 $(0,0,160,15,4)^T$, 相应的目标函数

$$\max z = 0$$



Simplex Method

Step 2: 判断当前解是否为最优解

将基变量用非基变量表示

$$x_3 = 160 - 30x_1 - 20x_2$$

$$x_4 = 15 - 5x_1 - x_2$$

$$x_5 = 4 - x_1$$

用非基变量表示目标函数

$$z = 0 + 5x_1 + 2x_2$$

从数学角度看, $z = 5x_1 + 2x_2$ 中非基变量 x_1, x_2 的系数为正数, 故若让非基变量 x_1 (or x_2) 的取值从零增加, 相应的目标函数的值也将增加, 因此有可能找到一个新的基本可行解, 使目标函数值比初始值 $x^{(0)}$ 的更好, 或者说得到了改善。

因此当前基本可行解不是最优解。



Simplex Method

Step 3: 解的改进

$z = 5x_1 + 2x_2$ 中, x_1 前面系数比 x_2 前面系数大, 即 x_1 每增加单位值对目标函数 z 的贡献比 x_2 大, 因此让 x_1 的取值从零变为正值.

故 x_1 从非基变量转为基变量, 称之为**进基变量**

但本例中, 任意一个基本可行解中只能有3个基变量, 因此必须从原有的基变量 x_3, x_4, x_5 中选择一个出去, 称之为**出基变量**

解的改进需面对三个问题:

(1) 选择进基变量; (2) 进基变量取多大的正值; (3) 选择出基变量
观察非基变量表示基变量的式子中, x_2 仍为0

$$x_3 = 160 - 30x_1 - 20x_2$$

$$x_4 = 15 - 5x_1 - x_2$$

$$x_5 = 4 - x_1$$



Simplex Method

Step 3: 解的改进

当 x_1 从零开始增加, 直到使 x_3, x_4, x_5 的取值减少到0时停止, 第一个变为0的基变量为出基变量

$$x_3 = 160 - 30x_1$$

$$x_4 = 15 - 5x_1$$

$$x_5 = 4 - x_1$$

显然 $x_1 = \min \left\{ \frac{160}{30}, \frac{15}{5}, \frac{4}{1} \right\} = 3$, 此时 $x_4 = 0$, 因此 x_4 为出基变量
将基变量转化为新的非基变量的形式, 即将下列式子转化

$$x_3 = 160 - 30x_1 - 20x_2$$

$$x_4 = 15 - 5x_1 - x_2$$

$$x_5 = 4 - x_1$$



Simplex Method

Step 3: 解的改进

$$x_1 = 3 - \frac{1}{5}x_2 - \frac{1}{5}x_4$$

$$x_3 = 160 - 30 \left(3 - \frac{1}{5}x_2 - \frac{1}{5}x_4 \right) - 20x_2 = 70 - 14x_2 + 6x_4$$

$$x_5 = 4 - \left(3 - \frac{1}{5}x_2 - \frac{1}{5}x_4 \right) = 1 + \frac{1}{5}x_2 + \frac{1}{5}x_4$$

因此可得到新的基本可行解为 $x^{(1)} = (3, 0, 70, 0, 1)^T$

Step 2: 判断当前解 $x^{(1)}$ 是否为最优解

用当前的非基变量表示目标函数

$$z = 5x_1 + 2x_2 = 5 \left(3 - \frac{1}{5}x_2 - \frac{1}{5}x_4 \right) + 2x_2 = 15 + x_2 - x_4$$



Simplex Method

Step 2: 判断当前解 $x^{(1)}$ 是否为最优解

用当前的非基变量表示目标函数

$$z = 15 + x_2 - x_4$$

从数学角度看， $z = 15 + x_2 - x_4$ 中非基变量 x_2 的系数为正数，故若让非基变量 x_2 的取值从零增加，相应的目标函数的值也将增加，因此有可能找到一个新的基本可行解，使目标函数值比初始值 $x^{(1)}$ 的更好或者改善。

因此当前基本可行解不是最优解。



Simplex Method

Step 3: 解的改进

$$z = 15 + x_2 - x_4$$

(1) 选择进基变量 x_2

非基变量表示基变量的式子中, $x_4 = 0$

$$\begin{aligned}x_1 &= 3 - \frac{1}{5}x_2 - \frac{1}{5}x_4 \\x_3 &= 70 - 14x_2 + 6x_4 \\x_5 &= 1 + \frac{1}{5}x_2 + \frac{1}{5}x_4\end{aligned}$$

化为

$$\begin{aligned}x_1 &= 3 - \frac{1}{5}x_2 \\x_3 &= 70 - 14x_2 \\x_5 &= 1 + \frac{1}{5}x_2\end{aligned}$$



Simplex Method

Step 3: 解的改进

$$\begin{aligned}x_1 &= 3 - \frac{1}{5}x_2 \\x_3 &= 70 - 14x_2 \\x_5 &= 1 + \frac{1}{5}x_2\end{aligned}$$

显然 $x_2 = \langle \min\{15, 5, -5\} \cup x_2 \geq 0 \rangle = 5$, 此时 $x_3 = 0$, 因此 x_3 为出基变量

将基变量转化为新的非基变量的形式, 即将下列式子转化

$$\begin{aligned}x_1 &= 3 - \frac{1}{5}x_2 - \frac{1}{5}x_4 \\x_3 &= 70 - 14x_2 + 6x_4 \\x_5 &= 1 + \frac{1}{5}x_2 + \frac{1}{5}x_4\end{aligned}$$



Simplex Method

Step 3: 解的改进

$$x_1 = 3 - \frac{1}{5} \left(5 - \frac{1}{14}x_3 + \frac{3}{7}x_4 \right) - \frac{1}{5}x_4 = 2 + \frac{1}{70}x_3 - \frac{2}{7}x_4$$

$$x_2 = 5 - \frac{1}{14}x_3 + \frac{3}{7}x_4$$

$$x_5 = 1 + \frac{1}{5} \left(5 - \frac{1}{14}x_3 + \frac{3}{7}x_4 \right) + \frac{1}{5}x_4 = 2 - \frac{1}{70}x_3 + \frac{2}{7}x_4$$

目标函数转化为

$$z = 15 + 5 - \frac{1}{14}x_3 + \frac{3}{7}x_4 - x_4 = 20 - \frac{1}{14}x_3 - \frac{4}{7}x_4$$

因此可得到新的基本可行解为 $x^{(2)} = (2, 5, 0, 0, 2)^T$

因此目标函数取得最大值 $z=20$



整数规划问题

线性规划问题中，决策变量具有不可分割性，如设备的台数、项目的个数、人员数等。

- 规划问题中所有决策变量都取整数，则称其为纯整数规划问题
- 若部分决策变量要求取整数，称其为混合整数规划问题
- 若决策变量只能取0或1，则称其为0-1型整数线性规划问题

典型的求解方法有割平面法和分枝定界法。



整数规划问题

Case 1 外贸企业出口某些化工原料时采用集装箱船运，集装箱最大容量为 V_0 ，现有 n 种桶装原料可供选择装入集装箱，每种原料桶数不限，设第 i 种物品每桶的体积为 V_i ($i = 1, 2, \dots, n$)，相应的利润为 c_i ，问每种原料各取多少桶装入集装箱，使集装箱中货物的利润最高？

Solution: 设第 i 种原料有 x_i 桶装入集装箱，则有

$$\max z = c_1x_1 + c_2x_2 + \dots + c_nx_n$$

$$s. t. V_1x_1 + V_2x_2 + \dots + V_nx_n \leq V_0$$

$$x_1, x_2, \dots, x_n \geq 0, x_1, x_2, \dots, x_n \in integer$$



整数规划问题

Case 2 某供销社在疫情期间保供，由近期工作量估计得出一周中每天所需保供人数为：周一至少需 a_1 人，周二至少需 a_2 人， $\dots$ ，周日至少需 a_7 人，为实现疫情防控物资保供到位，规定每个保供员连续工作5天方可休息2天，问该供销社一周中每天需多少保供员，既能满足保供需要，又使得一周中总保供人数最少？



整数规划问题

Solution: 设从周一刚开始参与保供的保供员 x_1 人, 从周二刚开始参与保供的保供员 x_2 人, ..., 从周日刚开始参与保供的保供员 x_7 人

$$\begin{aligned} \min z &= x_1 + x_2 + \cdots + x_7 \\ s. t. \quad & \begin{aligned} x_1 + x_4 + x_5 + x_6 + x_7 &\geq a_1 \\ x_1 + x_2 + x_5 + x_6 + x_7 &\geq a_2 \\ x_1 + x_2 + x_3 + x_6 + x_7 &\geq a_3 \\ x_1 + x_2 + x_3 + x_4 + x_7 &\geq a_4 \\ x_1 + x_2 + x_3 + x_4 + x_5 &\geq a_5 \\ x_2 + x_3 + x_4 + x_5 + x_6 &\geq a_6 \\ x_3 + x_4 + x_5 + x_6 + x_7 &\geq a_7 \\ x_i &\geq 0 \text{ \& } x_i \in integer \end{aligned} \end{aligned}$$



整数规划问题

整数规划问题需要得到整数解，是否能够不管整数要求，将该问题进行线性规划求解，然后求得非整数解再舍零取整是否可以？

答案是：不可行，有时候舍零取整后的整数解根本就不是可行解，有时候舍零取整后得到的是可行解，但不是最优解。



整数规划问题

Case 3 疫情期间某核酸采样点进行核酸采集，核酸采集分黄码和绿码两种，每个样品采集的耗时、成本消耗、收取费用以及采样量的限制见下表，问每天黄码、绿码人员样品采集各多少个，可获得利润最大？

采样对象/人	采样耗时/min	单人成本/元	单人收费/元
绿码	4	0.2	2.2
黄码	5	5	6
限制	1440	1300	



整数规划问题

Solution: 设每天采样人群中为绿码人数 x_1 , 黄码人数为 x_2

$$\begin{aligned} \max z &= 2x_1 + x_2 \\ \text{s.t.} \quad &4x_1 + 5x_2 \leq 1440 \\ &0.2x_1 + 5x_2 \leq 1300 \\ &x_i \geq 0 \text{ \& } x_i \in \textit{integer} \end{aligned}$$

若不考虑整数问题, 则该优化问题可转化为

$$\begin{aligned} \max z &= 2x_1 + x_2 \\ \text{s.t.} \quad &4x_1 + 5x_2 \leq 1440 \\ &0.2x_1 + 5x_2 \leq 1300 \\ &x_i \geq 0 \end{aligned}$$

简单的线性规划问题, 称为整数规划的伴随规划。

解为 $\mathbf{x}^* = (360, 0)^T$, 最优值 $z^* = 720$



整数规划问题

Case 4 疫情期间某核酸采样点进行核酸采集时按黄码队伍和绿码队伍分别进行，样品采集时绿码每10人一管，黄码为单人单管，样品采集后需进行样品处理和分析，样品处理分析过程中耗时、样品处理某制剂消耗等限制及利润数据见下表，问每天黄码、绿码样品采集各多少管，可获得利润最大？

采样对象/管	样品处理分析 耗时/min	样本制剂消耗限 制/百公斤	利润/元
绿码	5	2	20
黄码	4	5	10
限制	24	13	



整数规划问题

Solution: 设每天采样人群中为绿码人数 x_1 , 黄码人数为 x_2

$$\begin{aligned} \max z &= 20x_1 + 10x_2 \\ \text{s.t.} \quad &5x_1 + 4x_2 \leq 24 \\ &2x_1 + 5x_2 \leq 13 \\ &x_i \geq 0 \text{ \& } x_i \in \textit{integer} \end{aligned}$$

若不考虑整数问题, 则该优化问题也可转化为

$$\begin{aligned} \max z &= 20x_1 + 10x_2 \\ \text{s.t.} \quad &5x_1 + 4x_2 \leq 24 \\ &2x_1 + 5x_2 \leq 13 \\ &x_i \geq 0 \end{aligned}$$

简单的线性规划问题, 解为 $\mathbf{x}^* = (4.8, 0)^T$, 最优值 $z^* = 96$
舍零取整后的解为 $\mathbf{x} = (5, 0)^T$ 不是原规划问题的可行解。若取 $\mathbf{x} = (4, 0)^T$ 是优化问题的可行解, 但不是最优解。最优解为 $\mathbf{x} = (4, 1)^T$



整数规划问题--分枝定界法

分枝定界法思路：

- (1)求解整数规划的伴随规划问题，若求解的最优解不符合整数条件，则增加新约束条件以便缩小可行域，将原整数规划问题分枝两个子规划
- (2)解子规划的伴随规划，通过求解一些列子规划的伴随规划问题，从而不断定界，最后得到原整数规划问题的整数最优解



整数规划问题--分枝定界法

Example:

$$\max z = 10x_1 + 20x_2$$

$$s.t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1, x_2 \geq 0 \text{ \& } x_1, x_2 \in integer$$

假设该问题为A，其伴随规划问题为B

- 若伴随规划问题B无可行解，则原整数规划问题A无可行解
- 若伴随规划问题的最优解满足整数规划的整数条件，则该最优解也为原整数规划的最优解

上述问题的伴随规划问题解为 $\mathbf{x}^* = (5.6, 4)^T, z = 136$



整数规划问题--分枝定界法

对该解 $\mathbf{x}^* = (5.6, 4)^T$ 进行分枝

第1步：计算原问题A目标函数值的初始上界 $\bar{z}$

由于问题B的最优解不满足整数条件，故不是A的最优解，但是问题A的可行域 $\subset$ 问题B的可行域，那么 $z^* \leq 136$ ，于是问题A目标函数值的初始上界 $\bar{z} = 136$

第2步：计算原问题A目标函数值的初始下界 $\underline{z}$

若能从问题A的约束条件中观察到一个整数可行解，则可将其目标函数值作为问题A目标函数的初始下界，否则可令其初始下界为 $\underline{z} = -\infty$

Example中 $x_1 = x_2 = 0$ 为可行解，故 $\underline{z} = 0$



整数规划问题--分枝定界法

第3步：增加约束条件将原问题A分枝

问题B的最优解 $\mathbf{x}^* = (5.6, 4)^T$ 中 $5 \leq x_1 = 5.6 \leq 6$ ，若 x_1 取整数智能为 $x_1 \geq 6$ 或者 $x_1 \leq 5$ ，为此可以将原问题分解为

问题A1

$$\max z = 10x_1 + 20x_2$$

$$s. t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \leq 5$$

$$x_1, x_2 \geq 0 \text{ \& } x_1, x_2 \in integer$$

问题A2

$$\max z = 10x_1 + 20x_2$$

$$s. t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \geq 6$$

$$x_1, x_2 \geq 0 \text{ \& } x_1, x_2 \in integer$$



整数规划问题--分枝定界法

第4步：分别求每一个分枝

对分枝问题的伴随问题求解，可能出现以下情形：

➤无可行解

说明该分枝已经明确，无需对其继续分枝，称该分枝为“明枝”

➤得到整数最优解

则该分支情况也明确，无需对其继续分枝，也称该分枝为“明枝”

➤得到不满足整数条件的最优解

(1)该最优解的目标函数值 z 小于当前下界 $\underline{z}$ ，故该分枝内不可能含有原问题的整数最优解，故无需对其继续分枝，称之为“枯枝”，需剪掉



整数规划问题--分枝定界法

第4步：分别求每一个分枝

➤得到不满足整数条件的最优解

(2)该最优解的目标函数值 z 大于当前下界 $\underline{z}$ ，仍需对该枝继续分枝，以明确该分枝内是否有目标函数值比当前的 $\underline{z}$ 更好的整数最优解

若一对分枝需要继续分枝定时，首先对目标函数值较优的分枝求解，待目标函数较优的那枝全部分解到不能再分，全部明确时为止，再回过头来考虑目标函数值稍差的那枝



整数规划问题--分枝定界法

第5步：修改上界 $\bar{z}$ 和下界 $\underline{z}$

►修改上界 $\bar{z}$ 和下界 $\underline{z}$

修改下界的时机：每当求出一个整数可行解，须修改下界 $\underline{z}$

修改下界 $\underline{z}$ 的原则：在当前全部整数可行解中，选目标函数值最大的那个作为最新下界 $\underline{z}$

►修改上界 $\bar{z}$

修改上界 $\bar{z}$ 的时机：每求解完一对分枝，须考虑修改上界 $\bar{z}$

修改上界 $\bar{z}$ 的原则：挑选目前为止所有未被分枝定问题的目标函数值中的最大一个作为新的上界



整数规划问题--分枝定界法

第5步：结束准则

当所有分枝均已明确(无可行解--“明枝”， 或为整数可行解--“明枝”， 或其目标函数值不大于下界 $\underline{z}$ --“枯枝”), 且此时 $\bar{z} = \underline{z}$, 则已经到了原问题的整数最优解, 即目标函数值为下界 $\underline{z}$ 的那个整数解

整数规划问题--分枝定界法



问题B $\mathbf{x}^* = (5.6, 4)^T, z = 136$

$\bar{z} = 136, \underline{z} = 0$

伴随问题B1

$$\max z = 10x_1 + 20x_2$$

$$s.t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \leq 5$$

$$x_1, x_2 \geq 0$$

Solution: $\mathbf{x}^* = (5, 4)^T$

$$z_1 = 130$$

$\bar{z} = 135, \underline{z} = 130$

伴随问题B2

$$\max z = 10x_1 + 20x_2$$

$$s.t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \geq 6$$

$$x_1, x_2 \geq 0$$

$\mathbf{x}^* = (6, 3.75)^T$

$$z_1 = 135$$

整数规划问题--分枝定界法



$$\bar{z} = 135, \underline{z} = 130$$

问题A3

$$\max z = 10x_1 + 20x_2$$

$$s.t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \leq 5$$

$$x_2 \leq 3$$

$$x_1, x_2 \geq 0 \text{ \& } x_1, x_2 \in integer$$

问题A4

$$\max z = 10x_1 + 20x_2$$

$$s.t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \geq 6$$

$$x_2 \geq 4$$

$$x_1, x_2 \geq 0 \text{ \& } x_1, x_2 \in integer$$

整数规划问题--分枝定界法



$$\bar{z} = 135, \underline{z} = 130$$

伴随问题B3

$$\max z = 10x_1 + 20x_2$$

$$s.t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \leq 5$$

$$x_2 \leq 3$$

$$x_1, x_2 \geq 0$$

Solution: $\mathbf{x}^* = (7.2, 3)^T$

$$z_2 = 132 \quad \bar{z} = 132, \underline{z} = 130$$

伴随问题B4

$$\max z = 10x_1 + 20x_2$$

$$s.t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \geq 6$$

$$x_2 \geq 4$$

$$x_1, x_2 \geq 0$$

No feasible solution

$$\bar{z} = 132, \underline{z} = 130$$

问题A5

$$\max z = 10x_1 + 20x_2$$

$$s. t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \leq 5$$

$$x_2 \leq 3$$

$$x_1 \leq 7$$

$$x_1, x_2 \geq 0 \text{ \& } x_1, x_2 \in \textit{integer}$$

问题A6

$$\max z = 10x_1 + 20x_2$$

$$s. t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \geq 6$$

$$x_2 \geq 4$$

$$x_1 \geq 8$$

$$x_1, x_2 \geq 0 \text{ \& } x_1, x_2 \in \textit{integer}$$

伴随问题B5

$$\max z = 10x_1 + 20x_2$$

$$s. t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \leq 5$$

$$x_2 \leq 3$$

$$x_1 \leq 7$$

$$x_1, x_2 \geq 0$$

$$\text{Solution: } \mathbf{x}^* = (7, 3)^T$$

$$z_3 = 130$$

$$\bar{z} = 130,$$

$$\bar{z} = 132, \underline{z} = 130$$

伴随问题B6

$$\max z = 10x_1 + 20x_2$$

$$s. t. 5x_1 + 8x_2 \leq 60$$

$$x_1 \leq 8$$

$$x_2 \leq 4$$

$$x_1 \geq 6$$

$$x_2 \geq 4$$

$$x_1 \geq 8$$

$$x_1, x_2 \geq 0$$

$$\mathbf{x}^* = (8, 2.5)^T$$

$$z_3 = 130$$

$$\underline{z} = 130$$



二次规划问题

二次规划属于非线性规划中的一种，它的目标函数是二次函数，约束函数都是线性函数。二次规划相对较简单，便于求解（仅次于线性规划），一些非线性优化问题也可以转化为求解一系列的二次规划问题。

求解二次规划的算法较多，本部分介绍求解等式约束凸二次规划的零空间方法和拉格朗日乘子法。

*等式约束凸二次规划问题

$$\begin{aligned} \min & \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{c}^T \mathbf{x} \quad (***) \\ \text{s.t.} & \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned}$$

式中： $\mathbf{H} \in \mathbf{R}^{n \times n}$ 对称正定； $\mathbf{A} \in \mathbf{R}^{m \times n}$ 行满秩； $\mathbf{c}, \mathbf{x} \in \mathbf{R}^n$ ； $\mathbf{b} \in \mathbf{R}^m$



二次规划问题

► 零空间法

设 $\mathbf{x}_0$ 满足 $\mathbf{A}\mathbf{x}_0 = \mathbf{b}$, 记 $\mathbf{A}$ 的零空间为

$$N(\mathbf{A}) = \{\mathbf{z} \in \mathbf{R}^n | \mathbf{A}\mathbf{z} = \mathbf{0}\}$$

则问题(***)的任一可行点 $\mathbf{x}$ 可表示为 $\mathbf{x} = \mathbf{x}_0 + \mathbf{z} (\mathbf{z} \in N(\mathbf{A}))$, 则问题(***)可等价变形为

$$\begin{aligned} \min & \frac{1}{2} \mathbf{z}^T \mathbf{H} \mathbf{z} + \mathbf{z}^T (\mathbf{c} + \mathbf{H}\mathbf{x}_0) \quad (***) \quad 1) \\ \text{s.t.} & \mathbf{A}\mathbf{z} = \mathbf{0} \end{aligned}$$

若 $\mathbf{G} \in \mathbf{R}^{n \times (n-m)}$ 由 $N(\mathbf{A})$ 的一组基组成的矩阵, 则对任意的 $\mathbf{d} \in \mathbf{R}^{n-m}$ 有 $\mathbf{z} = \mathbf{G}\mathbf{d} \in N(\mathbf{A})$, 因此问题(***)1)可变为无约束优化问题

$$\min \frac{1}{2} \mathbf{d}^T (\mathbf{G}^T \mathbf{H} \mathbf{G}) \mathbf{d} + \mathbf{d}^T [\mathbf{G}^T (\mathbf{c} + \mathbf{H}\mathbf{x}_0)] \quad (***) \quad 2)$$



二次规划问题--零空间法

$$\min \frac{1}{2} \mathbf{d}^T (\mathbf{G}^T \mathbf{H} \mathbf{G}) \mathbf{d} + \mathbf{d}^T [\mathbf{G}^T (\mathbf{c} + \mathbf{H} \mathbf{x}_0)] \quad (***)$$

上述优化问题中若 $\mathbf{H}$ 半正定时, $\mathbf{G}^T \mathbf{H} \mathbf{G}$ 也是半正定, 此时假设 $\mathbf{d}^*$ 是问题(***)的平稳点, 则 $\mathbf{d}^*$ 也是优化问题(***)的全局极小点, 同时 $\mathbf{x}^* = \mathbf{x}_0 + \mathbf{G} \mathbf{d}^*$ 是优化问题(***)的全局极小点。该方法基于约束函数的系数矩阵的零空间, 因此称为零空间方法。 $\boldsymbol{\lambda}^* = \mathbf{A}^\&(\mathbf{H} \mathbf{x}^* + \mathbf{c})$ 是相应的拉格朗日乘子, $\mathbf{A}^\&$ 为矩阵 $\mathbf{A}$ 的广义逆。

余下的问题就是如何确定可行点 $\mathbf{x}_0$ 和零空间 $N(\mathbf{A})$ 的基矩阵 $\mathbf{G}$ 。有多种方法可以确定 $\mathbf{x}_0$ 和 $\mathbf{G}$ 。比如矩阵的QR分解:

$$\mathbf{A}^T = \mathbf{Q} \begin{pmatrix} \mathbf{R} \\ \mathbf{0} \end{pmatrix} = (\mathbf{Q}_1 \quad \mathbf{Q}_2) \begin{pmatrix} \mathbf{R} \\ \mathbf{0} \end{pmatrix}$$

式中: $\mathbf{Q}$ 为 n 阶正交阵; $\mathbf{R}$ 为一个 m 阶上三角阵; $\mathbf{Q}_1 \in R^{n \times m}$; $\mathbf{Q}_2 \in R^{n \times (n-m)}$, 由

$$\mathbf{A} \mathbf{x} = \mathbf{b} \rightarrow (\mathbf{A}^T)^T \mathbf{x} = \mathbf{b}$$



二次规划问题--零空间法

$$Ax = b \rightarrow (A^T)^T x = b$$

$$\left[Q \begin{pmatrix} R \\ 0 \end{pmatrix} \right]^T x = b$$

$$\begin{pmatrix} R \\ 0 \end{pmatrix}^T Q^T x = b$$

$$Q^T x = \begin{pmatrix} R \\ 0 \end{pmatrix}^{-T} b$$

$$QQ^T x = Q \begin{pmatrix} R \\ 0 \end{pmatrix}^{-T} b$$

$$x = Q \begin{pmatrix} R \\ 0 \end{pmatrix}^{-T} b$$

$$Q = (Q_1 \quad Q_2)$$

$$x_0 = Q_1 R^{-T} b, G = Q_2$$

$$A^\& = Q_1 R^{-T}$$



二次规划问题--零空间法

算法步骤

S0 输入矩阵 H , A 和向量 c , b

S1 对矩阵 A^T 进行QR分解的矩阵 Q_1, Q_2 和 R

S2 计算可行点 x_0 和零空间 $N(A)$ 的基矩阵 G

S3 求解无约束优化子问题的 d^*

S4 计算全局最小点 $x^* = x_0 + Gd^*$ 和相应的拉格朗日乘子 $\lambda^* = A^*(Hx^* + c)$



二次规划问题--拉格朗日乘子法

讨论两个变量的等式约束最优化问题

$$\begin{aligned} \min & f(x_1, x_2) \\ \text{s.t.} & g(x_1, x_2) = 0 \end{aligned}$$

假设在最优解处 $\frac{\partial g}{\partial x_2} \neq 0$ ，则在最优解附近由约束方程可解出 x_2 代入目标函数，则原优化问题转化为无约束优化问题，在最优解处目标函数应该满足

$$df = \frac{\partial f}{\partial x_1} dx_1 + \frac{\partial f}{\partial x_2} dx_2 = 0$$

将约束方程微分得

$$dg = \frac{\partial g}{\partial x_1} dx_1 + \frac{\partial g}{\partial x_2} dx_2 = 0$$

若将 df 加上某常数乘以 dg 可得

$$\frac{\partial f}{\partial x_1} dx_1 + \frac{\partial f}{\partial x_2} dx_2 + \lambda \left(\frac{\partial g}{\partial x_1} dx_1 + \frac{\partial g}{\partial x_2} dx_2 \right) = 0$$



二次规划问题--拉格朗日乘子法

$$\frac{\partial f}{\partial x_1} dx_1 + \frac{\partial f}{\partial x_2} dx_2 + \lambda \left(\frac{\partial g}{\partial x_1} dx_1 + \frac{\partial g}{\partial x_2} dx_2 \right) = 0$$

化简得

$$\left(\frac{\partial f}{\partial x_1} + \lambda \frac{\partial g}{\partial x_1} \right) dx_1 + \left(\frac{\partial f}{\partial x_2} + \lambda \frac{\partial g}{\partial x_2} \right) dx_2 = 0 \quad (1)$$

在最优解处, 由于 $\frac{\partial g}{\partial x_2} \neq 0$, 为此可选择 λ 使得下述方程等于零成立

$$\frac{\partial f}{\partial x_2} + \lambda \frac{\partial g}{\partial x_2} = 0$$

因此式(1)变为

$$\left(\frac{\partial f}{\partial x_1} + \lambda \frac{\partial g}{\partial x_1} \right) dx_1 = 0$$

由于 x_1 为决策变量, 因此可取任意值, 即 dx_1 可取任意值, 因此上式成立需

$$\frac{\partial f}{\partial x_1} + \lambda \frac{\partial g}{\partial x_1} = 0$$



二次规划问题--拉格朗日乘子法

因此通过上述分析确定的 λ, x_1^*, x_2^* 为原问题的最优解，为方便记忆，通常引入辅助函数

$$L(x_1, x_2, \lambda) = f(x_1, x_2) + \lambda g(x_1, x_2)$$

该函数称为拉格朗日函数，该函数若取得极值，其一阶导数为零，因此可得到前面所推导的结果

$$\begin{aligned}\frac{\partial L}{\partial x_1} &= \frac{\partial f}{\partial x_1} + \lambda \frac{\partial g}{\partial x_1} = 0 \\ \frac{\partial L}{\partial x_2} &= \frac{\partial f}{\partial x_2} + \lambda \frac{\partial g}{\partial x_2} = 0 \\ \frac{\partial L}{\partial \lambda} &= g(x_1, x_2) = 0\end{aligned}$$



二次规划问题--拉格朗日乘子法

$$\min \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{c}^T \mathbf{x} \quad (2)$$
$$s. t. \mathbf{A} \mathbf{x} = \mathbf{b}$$

$\mathbf{H} \in \mathbf{R}^{n \times n}$ 对称正定; $\mathbf{A} \in \mathbf{R}^{m \times n}$ 行满秩; $\mathbf{c}, \mathbf{x} \in \mathbf{R}^n$; $\mathbf{b} \in \mathbf{R}^m$
该问题的拉格朗日函数为

$$L(\mathbf{x}, \boldsymbol{\lambda}) = \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{c}^T \mathbf{x} + \boldsymbol{\lambda}^T (\mathbf{A} \mathbf{x} - \mathbf{b})$$

令

$$\nabla_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}) = \mathbf{0}, \nabla_{\boldsymbol{\lambda}} L(\mathbf{x}, \boldsymbol{\lambda}) = \mathbf{0}$$

得到方程组

$$\begin{aligned} \mathbf{H} \mathbf{x} - \mathbf{A}^T \boldsymbol{\lambda} &= -\mathbf{c} \\ -\mathbf{A} \mathbf{x} &= -\mathbf{b} \end{aligned}$$

方程组写成分块矩阵形式

$$\begin{pmatrix} \mathbf{H} & -\mathbf{A}^T \\ -\mathbf{A} & \mathbf{0} \end{pmatrix} \begin{pmatrix} \mathbf{x} \\ \boldsymbol{\lambda} \end{pmatrix} = \begin{pmatrix} -\mathbf{c} \\ -\mathbf{b} \end{pmatrix} \quad (3)$$



二次规划问题--拉格朗日乘子法

称上述方程组的系数矩阵

$$\begin{pmatrix} \mathbf{H} & -\mathbf{A}^T \\ -\mathbf{A} & \mathbf{0} \end{pmatrix}$$

为拉格朗日矩阵

方程组(3)有唯一解的充分条件为：

假设 $\mathbf{H} \in \mathbf{R}^{n \times n}$ 对称正定； $\mathbf{A} \in \mathbf{R}^{m \times n}$ 行满秩，若在问题(2)的解 $\mathbf{x}^*$ 处满足二阶充分条件，即

$$\mathbf{d}^T \mathbf{H} \mathbf{d} > 0, \forall \mathbf{d} \in \mathbf{R}^n, \mathbf{d} \neq \mathbf{0}, \mathbf{A} \mathbf{d} = \mathbf{0}$$

则方程组(3)的系数矩阵非奇异，即方程组(3)有唯一解。

该结论证明过程忽略.



二次规划问题--拉格朗日乘子法

根据上述结论，拉格朗日矩阵非奇异，故可设其逆为：

$$\begin{pmatrix} \mathbf{H} & -\mathbf{A}^T \\ -\mathbf{A} & \mathbf{0} \end{pmatrix}^{-1} = \begin{pmatrix} \mathbf{G} & -\mathbf{B}^T \\ -\mathbf{B} & \mathbf{C} \end{pmatrix}$$

则

$$\begin{pmatrix} \mathbf{H} & -\mathbf{A}^T \\ -\mathbf{A} & \mathbf{0} \end{pmatrix} \begin{pmatrix} \mathbf{G} & -\mathbf{B}^T \\ -\mathbf{B} & \mathbf{C} \end{pmatrix} = \begin{pmatrix} \mathbf{I}_n & \mathbf{0}_{n \times m} \\ \mathbf{0}_{m \times n} & \mathbf{I}_m \end{pmatrix}$$

得

$$\begin{aligned} \mathbf{H}\mathbf{G} + \mathbf{A}^T\mathbf{B} &= \mathbf{I}_n \\ -\mathbf{H}\mathbf{B}^T - \mathbf{A}^T\mathbf{C} &= \mathbf{0}_{n \times m} \\ -\mathbf{A}\mathbf{G} &= \mathbf{0}_{m \times n} \\ \mathbf{A}\mathbf{B}^T &= \mathbf{I}_m \end{aligned}$$

故

$$\begin{aligned} \mathbf{G} &= \mathbf{H}^{-1} - \mathbf{H}^{-1}\mathbf{A}^T(\mathbf{A}\mathbf{H}^{-1}\mathbf{A}^T)^{-1}\mathbf{A}\mathbf{H}^{-1} \\ \mathbf{B} &= (\mathbf{A}\mathbf{H}^{-1}\mathbf{A}^T)^{-1}\mathbf{A}\mathbf{H}^{-1} \\ \mathbf{C} &= -(\mathbf{A}\mathbf{H}^{-1}\mathbf{A}^T)^{-1} \end{aligned}$$



二次规划问题--拉格朗日乘子法

方程组(3)的解为：

$$\begin{pmatrix} \bar{x} \\ \bar{\lambda} \end{pmatrix} = \begin{pmatrix} H & -A^T \\ -A & 0 \end{pmatrix}^{-1} \begin{pmatrix} -c \\ -b \end{pmatrix} = \begin{pmatrix} G & -B^T \\ -B & C \end{pmatrix} \begin{pmatrix} -c \\ -b \end{pmatrix} = \begin{pmatrix} -Gc + B^T b \\ Bc - Cb \end{pmatrix}$$

$$G = H^{-1} - H^{-1}A^T(AH^{-1}A^T)^{-1}AH^{-1}$$

$$B = (AH^{-1}A^T)^{-1}AH^{-1}$$

$$C = -(AH^{-1}A^T)^{-1}$$