

3. 高斯牛顿法


3.1 概述

化学化工中某些物性如密度、比热容、汽化热、焓值以及过程的物理量之间的相互关系，例如组分之间的相平衡关系、传热特征数关系等等，此类数据和关系大多以图表形式存在，若能将图表或者曲线表达为数学形式，将更方便计算机编程计算使用。精馏塔中计算理论板数的吉利兰（Gilliland）关联图就属于此类情形。

此外，科学实验过程中探求某种未知规律 $y = f(x)$ ，本质上 x 与 y 之间由实验数据来呈现，即利用实验测试点 $(x_i, y_i), i = 1, 2, \dots, n$ 获得数学模型。

3.2 Cases

Case 1 利用如下所示的吉利兰关联图，横坐标为自变量 $x = \frac{R-R_{min}}{R+1}$ ，纵坐标为因变量 $y = \frac{N-N_{min}}{N+2}$ ，在曲线上取若干个点 (x_i, y_i) ，每一个 x_i 均有一个 y_i 与之对应，数据如表所示。



i	x_i	y_i	i	x_i	y_i
1	0.01	0.69	6	0.3	0.37
2	0.02	0.67	7	0.4	0.21
3	0.04	0.62	8	0.5	0.24
4	0.1	0.54	9	0.9	0.16
5	0.2	0.45	10	1	0.0

根据表中 10 个数据点或者 10 个实验数据点，将该曲线拟合得到一个数学表达式。

Solution:

将 Gilliland 关联图写成与函数典型图形相对照，选定该曲线的数学函数模型为幂函数形式

$$y = a + bx^m$$

将 $x_i(i = 1, 2, \dots, 10)$ 代入上式，则有计算值 $y_i^c(i = 1, 2, \dots, 10)$ 与之对应

$$y_1^c = a + bx_1^m$$

$$y_2^c = a + bx_2^m$$

.....

$$y_{10}^c = a + bx_{10}^m$$

为了确保得到的拟合函数即数学模型能更好的反映此类实验数据, 现在设计一个平方和函数来评价该拟合函数, 即将计算值 $y_i^c (i = 1, 2, \dots, 10)$ 与实验值 $y_i (i = 1, 2, \dots, 10)$ 相减的平方和作为评价指标, 即


$$S = \sum_{i=1}^{10} (y_i^c - y_i)^2 = \sum_{i=1}^{10} [(a + bx_i^m) - y_i]^2 = \sum_{i=1}^{10} [f_i(a, b, m) - y_i]^2$$

由于上式中 $x_i, y_i (i = 1, 2, \dots, 10)$ 均已知, 而 a, b, m 为待定的参数, 参数值不同所对应的函数 S 的值相应改变。因此函数 S 实际上为三个变量的函数, 即可记为 $S(a, b, m)$, 当参数 a, b, m 取 a^*, b^*, m^* 时满足

$$S = \min \sum_{i=1}^{10} [f_i(a, b, m) - y_i]^2$$

时, 才可认为所得到的数学模型 $y = a^* + b^* x^{m^*}$ 与实验数据拟合得最好。

Case 2 某等温积分反应器的反应动力学实验测得某化学反应方程式为



当 $t = 0$ 时, $c_{A0} = 1, c_{B0} = 0, c_{C0} = 0$ 。由于 $c_A + c_B + c_C = 1$, 因此描述反应器出口反应物浓度的变化方程只需要 2 个即可

$$c_A = e^{-k_1 t}$$

$$c_B = \frac{k_1}{k_2 - k_1} (e^{-k_1 t} - e^{-k_2 t})$$

上述方程中自变量为 t , 因变量为 c_A, c_B ; k_1, k_2 为待定参数。由实验测得的实验数据见下表:

i	t_i	c_A	c_B	i	t_i	c_A	c_B
1	0	1.000	0.000	6	50	0.137	0.571
2	5	0.840	0.155	7	80	0.030	0.502
3	10	0.679	0.327	8	100	0.006	0.385
4	15	0.503	0.426	9	200	0.000	0.145
5	20	0.425	0.477				

当 $t = 15$ 时, 重复实验测得数据如下

t_i	c_A	c_B
	0.476	0.442
	0.488	0.419
15	0.548	0.426
	0.495	0.409
	0.508	0.432

Solution:

该问题数学模型的形式已经给定, 将实验值 t_i 代入给定的模型, 即可计算得到 c_{Ai}^c 和 c_{Bi}^c , 即有

$$c_{A1}^c = e^{-k_1 t_1} \quad c_{B1}^c = \frac{k_1}{k_2 - k_1} (e^{-k_1 t_1} - e^{-k_2 t_1})$$

$$c_{A2}^c = e^{-k_1 t_2} \quad c_{B2}^c = \frac{k_1}{k_2 - k_1} (e^{-k_1 t_2} - e^{-k_2 t_2})$$

$$\vdots \quad \quad \quad \vdots$$

$$c_{A9}^c = e^{-k_1 t_9} \quad c_{B9}^c = \frac{k_1}{k_2 - k_1} (e^{-k_1 t_9} - e^{-k_2 t_9})$$

若将计算得到的 c_{Ai}^c, c_{Bi}^c 与实验数据之间的残差平方和分别记为 S_A, S_B ，则可得到

$$S_A = \sum_{i=1}^9 (c_{Ai}^c - c_{Ai})^2 = \sum_{i=1}^9 (e^{-k_1 t_i} - c_{Ai})^2$$

$$S_B = \sum_{i=1}^9 (c_{Bi}^c - c_{Bi})^2 = \sum_{i=1}^9 \left[\frac{k_1}{k_2 - k_1} (e^{-k_1 t_i} - e^{-k_2 t_i}) - c_{Bi} \right]^2$$

类似 Case 1 可以采取如下指标对拟合结果进行评价来确定 k_1, k_2 ，即

$$S_A = \min \sum_{i=1}^9 (e^{-k_1 t_i} - c_{Ai})^2 = \min \sum_{i=1}^9 [f_{1i}(k_1) - c_{Ai}]^2$$

$$S_B = \min \sum_{i=1}^9 \left[\frac{k_1}{k_2 - k_1} (e^{-k_1 t_i} - e^{-k_2 t_i}) - c_{Bi} \right]^2 = \min \sum_{i=1}^9 [f_{2i}(k_1, k_2) - c_{Bi}]^2$$

由于反应速率常数 k_1, k_2 非独立，因此可将上述 2 式合并，即

$$S = \min \left\{ \sum_{i=1}^9 [f_{1i}(k_1) - c_{Ai}]^2 + \sum_{i=1}^9 [f_{2i}(k_1, k_2) - c_{Bi}]^2 \right\}$$

又为了确保模型对各观察值的残差效应与各自的实验误差相一致，合并后的目标函数各项需适当加以权重，根据实验重复测得的 c_A, c_B 数据的误差分析，取目标函数中第一项的权重值为 1.0，第二项的权重值为 4.9，则加权后的目标函数为

$$S = \min \left\{ \sum_{i=1}^9 [f_{1i}(k_1) - c_{Ai}]^2 + 4.9 \times \sum_{i=1}^9 [f_{2i}(k_1, k_2) - c_{Bi}]^2 \right\}$$

由此得到满足目标函数值的 k_1^*, k_2^* 确定相应的模型。有关模型差分检验、误差分析得到权重值不在本课程的讨论之列，因此不做进一步讨论，有兴趣的同学可以查阅相关文献或资料。

3.3 平方和形式的函数

上述讨论的问题中若不考虑具体待定参数 a, b, m 和 k_1, k_2 的物理意义，将待定参数待优化的变量 $\mathbf{x} (\mathbf{x} \in R^n)$ 来表示，则此类问题的数学模型一般形式为

$$Z(\mathbf{x}) = \sum_{l=1}^k f_l^2(\mathbf{x}) = \mathbf{F}(\mathbf{x})^T \mathbf{F}(\mathbf{x}) \quad (\mathbf{x} \in R^n)$$

其中

$$\mathbf{F}(\mathbf{x}) = [f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_k(\mathbf{x})]^T$$

是一个向量，每个向量的元为一个残差函数。 $f_l(\mathbf{x}) (l = 1, 2, \dots, k)$ 是 n 维函数的具体表达形式，例如 Case 1 中的 $a + bx_i^m - y_i$ ，Case 2 中的 $e^{-k_1 t_i} - c_{Ai}$ 及 $\frac{k_1}{k_1 - k_2} (e^{-k_1 t_i} - e^{-k_2 t_i}) - c_{Bi}$ 。

平方和形式的目标函数在曲线拟合和实验数据处理中经常遇到。此外，有时也可将非线性方程组如

$$\begin{aligned} y_1(\mathbf{x}) &= b_1 \\ y_2(\mathbf{x}) &= b_2 \\ &\vdots \end{aligned}$$

$$y_m(\mathbf{x}) = b_m$$

转化为

$$Z(\mathbf{x}) = \sum_{l=1}^k [y_l(\mathbf{x}) - b_l]^2 = \sum_{l=1}^k f_l^2(\mathbf{x}) = \mathbf{F}(\mathbf{x})^T \mathbf{F}(\mathbf{x})$$

并求极小，当满足

$$\min Z(\mathbf{x}) = \sum_{l=1}^k f_l^2(\mathbf{x})$$

的最优解 $\mathbf{x}^* = (x_1^*, x_2^*, \dots, x_n^*)^T$ 就是原方程组的解，其中 $f_l(\mathbf{x}) = y_l(\mathbf{x}) - b_l, l = 1, 2, \dots, k$ 。如果向量函数 $\mathbf{F}(\mathbf{x})$ 中的分量 $f_l(\mathbf{x}) (l = 1, 2, \dots, k)$ 均为 $\mathbf{x} \in R^n$ 的线性函数，则称该优化问题为线性最小二乘问题，否则称为非线性最小二乘，该问题所对应的最优解为最小二乘解。对于此类问题可以采用前面所介绍的方法进行求解，但由此类函数本身所具有的特点，对某些方法加以适当修正，可以改善此类函数的求解使之变得更为简单、有效。比如前面所介绍的牛顿法具有较高的收敛速度，但每次迭代都必须计算一个二阶偏导数矩阵及其逆阵。由于平方和形式目标函数的特殊性，可采用各函数 $f_l(\mathbf{x})$ 的一阶导数来近似 $Z(\mathbf{x})$ 的二阶导数，由此使得牛顿法用于此类函数的求解具有更简单的形式，即所谓的高斯-牛顿法(Gauss-Newton Method)，也就是常说的最小二乘法。

3.4 高斯-牛顿法

函数 $f_l(\mathbf{x}) (l = 1, 2, \dots, k)$ 在某点 $\mathbf{x}^k$ 的一阶偏导容易求得，且将其一阶偏导写成如下形式：

$$J^k = \begin{bmatrix} \frac{\partial f_{l1}(\mathbf{x}^k)}{\partial x_1} & \frac{\partial f_{l1}(\mathbf{x}^k)}{\partial x_2} & \dots & \frac{\partial f_{l1}(\mathbf{x}^k)}{\partial x_n} \\ \frac{\partial f_{l2}(\mathbf{x}^k)}{\partial x_1} & \frac{\partial f_{l2}(\mathbf{x}^k)}{\partial x_2} & \dots & \frac{\partial f_{l2}(\mathbf{x}^k)}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_{lk}(\mathbf{x}^k)}{\partial x_1} & \frac{\partial f_{lk}(\mathbf{x}^k)}{\partial x_2} & \dots & \frac{\partial f_{lk}(\mathbf{x}^k)}{\partial x_n} \end{bmatrix} = \begin{bmatrix} j_{11}^k & j_{12}^k & \dots & j_{1n}^k \\ j_{21}^k & j_{22}^k & \dots & j_{2n}^k \\ \vdots & \vdots & \ddots & \vdots \\ j_{k1}^k & j_{k2}^k & \dots & j_{kn}^k \end{bmatrix} = [j_{li}^k]_{k \times n}$$

为函数 $\mathbf{F}(\mathbf{x})$ 在点 $\mathbf{x}^k$ 处的 Jacobin 矩阵，为一个 $k \times n$ 矩阵。由于

$$\frac{\partial Z(\mathbf{x})}{\partial x_i} = \frac{\partial}{\partial x_i} \left[\sum_{l=1}^k f_l^2(\mathbf{x}) \right] = 2 \sum_{l=1}^k f_l(\mathbf{x}) \frac{\partial f_l(\mathbf{x})}{\partial x_i} \quad (i = 1, 2, \dots, n)$$

并结合上述 Jacobin 矩阵，则

$$\nabla Z(\mathbf{x}^k) = 2(J^k)^T \mathbf{F}(\mathbf{x}^k)$$

若 $\mathbf{x}^k$ 为第 k 次迭代得到的近似极小点，为迭代得到 $\mathbf{x}^{k+1}$ ，将函数 $f_l(\mathbf{x}) (l = 1, 2, \dots, k)$ 在点 $\mathbf{x}^k$ 处用 Taylor 展开，取到一阶项有

$$f_l(\mathbf{x}) = f_l(\mathbf{x}^k) + \sum_{i=1}^n \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) + o\|\mathbf{x} - \mathbf{x}^k\|$$

取近似函数

$$f_l(\mathbf{x}) = f_l(\mathbf{x}^k) + \sum_{i=1}^n \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k)$$

则目标函数的近似式为

$$\tilde{Z}(\mathbf{x}) = \sum_{l=1}^k f_l^2(\mathbf{x}) = \sum_{l=1}^k \left[f_l(\mathbf{x}^k) + \sum_{i=1}^n \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) \right]^2$$

*****方便理解进行部分补充说明*****

若 $k = 2, n = 3$, 将上式展开则有

$$\begin{aligned} \tilde{Z}(\mathbf{x}) &= \sum_{l=1}^k f_l^2(\mathbf{x}) = \sum_{l=1}^k \left[f_l(\mathbf{x}^k) + \sum_{i=1}^n \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) \right]^2 \\ &= \left[f_1(x_1^k, x_2^k, x_3^k) + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_2} (x_2 - x_2^k) \right. \\ &\quad \left. + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_3} (x_3 - x_3^k) \right]^2 \\ &\quad + \left[f_2(x_1^k, x_2^k, x_3^k) + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_2} (x_2 - x_2^k) \right. \\ &\quad \left. + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_3} (x_3 - x_3^k) \right]^2 \end{aligned}$$

$$\begin{aligned} \frac{\partial \tilde{Z}(\mathbf{x})}{\partial x_1} &= 2 \left[f_1(x_1^k, x_2^k, x_3^k) + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_2} (x_2 - x_2^k) \right. \\ &\quad \left. + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_1} \\ &\quad + 2 \left[f_2(x_1^k, x_2^k, x_3^k) + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_2} (x_2 - x_2^k) \right. \\ &\quad \left. + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_1} \\ &= 2 \sum_{l=1}^2 \left[f_l(\mathbf{x}^k) + \sum_{i=1}^3 \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) \right] \frac{\partial f_l(\mathbf{x}^k)}{\partial x_1} \\ &= 2 \sum_{l=1}^2 \left[f_l(\mathbf{x}^k) + \sum_{i=1}^3 j_{li}^k (x_i - x_i^k) \right] j_{l1}^k \\ &= 2 \left[\sum_{l=1}^2 f_l(\mathbf{x}^k) j_{l1}^k + \sum_{l=1}^2 \sum_{i=1}^3 j_{l1}^k j_{li}^k (x_i - x_i^k) \right] \end{aligned}$$

$$\begin{aligned}
\frac{\partial \tilde{Z}(\mathbf{x})}{\partial x_2} &= 2 \left[f_1(x_1^k, x_2^k, x_3^k) + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_2} (x_2 - x_2^k) \right. \\
&\quad \left. + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_2} \\
&\quad + 2 \left[f_2(x_1^k, x_2^k, x_3^k) + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_2} (x_2 - x_2^k) \right. \\
&\quad \left. + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_2} \\
&= 2 \left[\sum_{l=1}^2 f_l(\mathbf{x}^k) j_{l2}^k + \sum_{l=1}^2 \sum_{i=1}^3 j_{l2}^k j_{li}^k (x_i - x_i^k) \right]
\end{aligned}$$

$$\begin{aligned}
\frac{\partial \tilde{Z}(\mathbf{x})}{\partial x_3} &= 2 \left[f_1(x_1^k, x_2^k, x_3^k) + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_2} (x_2 - x_2^k) \right. \\
&\quad \left. + \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_1(x_1^k, x_2^k, x_3^k)}{\partial x_3} \\
&\quad + 2 \left[f_2(x_1^k, x_2^k, x_3^k) + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_2} (x_2 - x_2^k) \right. \\
&\quad \left. + \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_2(x_1^k, x_2^k, x_3^k)}{\partial x_3} \\
&= 2 \left[\sum_{l=1}^2 f_l(\mathbf{x}^k) j_{l3}^k + \sum_{l=1}^2 \sum_{i=1}^3 j_{l3}^k j_{li}^k (x_i - x_i^k) \right]
\end{aligned}$$

$$\nabla \tilde{Z}(\mathbf{x}) = \begin{bmatrix} \frac{\partial \tilde{Z}(\mathbf{x})}{\partial x_1} \\ \frac{\partial \tilde{Z}(\mathbf{x})}{\partial x_2} \\ \frac{\partial \tilde{Z}(\mathbf{x})}{\partial x_3} \end{bmatrix} = 2 \begin{bmatrix} \sum_{l=1}^2 \left[f_l(\mathbf{x}^k) + \sum_{i=1}^3 \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) \right] \frac{\partial f_l(\mathbf{x}^k)}{\partial x_1} \\ \sum_{l=1}^2 \left[f_l(\mathbf{x}^k) + \sum_{i=1}^3 \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) \right] \frac{\partial f_l(\mathbf{x}^k)}{\partial x_2} \\ \sum_{l=1}^2 \left[f_l(\mathbf{x}^k) + \sum_{i=1}^3 \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) \right] \frac{\partial f_l(\mathbf{x}^k)}{\partial x_3} \end{bmatrix}$$

$$= 2 \begin{bmatrix} \sum_{l=1}^2 f_l(\mathbf{x}^k) j_{l1}^k + \sum_{l=1}^2 \sum_{i=1}^3 j_{l1}^k j_{li}^k (x_i - x_i^k) \\ \sum_{l=1}^2 f_l(\mathbf{x}^k) j_{l2}^k + \sum_{l=1}^2 \sum_{i=1}^3 j_{l2}^k j_{li}^k (x_i - x_i^k) \\ \sum_{l=1}^2 f_l(\mathbf{x}^k) j_{l3}^k + \sum_{l=1}^2 \sum_{i=1}^3 j_{l3}^k j_{li}^k (x_i - x_i^k) \end{bmatrix}$$

$$\nabla^2 \tilde{Z}(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_1 \partial x_2} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_1 \partial x_3} \\ \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_2^2} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_2 \partial x_3} \\ \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_3 \partial x_1} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_3 \partial x_2} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_3^2} \end{bmatrix}$$

$$\begin{aligned} \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_2^2} &= \frac{\partial}{\partial x_2} \left\{ 2 \left[f_1(\mathbf{x}^k) + \frac{\partial f_1(\mathbf{x}^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_1(\mathbf{x}^k)}{\partial x_2} (x_2 - x_2^k) \right. \right. \\ &\quad \left. \left. + \frac{\partial f_1(\mathbf{x}^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_1(\mathbf{x}^k)}{\partial x_2} \right. \\ &\quad \left. + 2 \left[f_2(\mathbf{x}^k) + \frac{\partial f_2(\mathbf{x}^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_2(\mathbf{x}^k)}{\partial x_2} (x_2 - x_2^k) \right. \right. \\ &\quad \left. \left. + \frac{\partial f_2(\mathbf{x}^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_2(\mathbf{x}^k)}{\partial x_2} \right\} = 2 \frac{\partial f_1(\mathbf{x}^k)}{\partial x_2} \frac{\partial f_1(\mathbf{x}^k)}{\partial x_2} + 2 \frac{\partial f_2(\mathbf{x}^k)}{\partial x_2} \frac{\partial f_2(\mathbf{x}^k)}{\partial x_2} \\ &= 2 j_{12}^k j_{12}^k + 2 j_{22}^k j_{22}^k = 2 \sum_{l=1}^2 j_{l2}^k j_{l2}^k \end{aligned}$$

$$\begin{aligned}
\frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_2 \partial x_3} &= \frac{\partial}{\partial x_3} \left\{ 2 \left[f_1(\mathbf{x}^k) + \frac{\partial f_1(\mathbf{x}^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_1(\mathbf{x}^k)}{\partial x_2} (x_2 - x_2^k) \right. \right. \\
&\quad \left. \left. + \frac{\partial f_1(\mathbf{x}^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_1(\mathbf{x}^k)}{\partial x_2} \right. \\
&\quad \left. + 2 \left[f_2(\mathbf{x}^k) + \frac{\partial f_2(\mathbf{x}^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_2(\mathbf{x}^k)}{\partial x_2} (x_2 - x_2^k) \right. \right. \\
&\quad \left. \left. + \frac{\partial f_2(\mathbf{x}^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_2(\mathbf{x}^k)}{\partial x_2} \right\} = 2 \frac{\partial f_1(\mathbf{x}^k)}{\partial x_3} \frac{\partial f_1(\mathbf{x}^k)}{\partial x_2} + 2 \frac{\partial f_2(\mathbf{x}^k)}{\partial x_3} \frac{\partial f_2(\mathbf{x}^k)}{\partial x_2} \\
&= 2j_{12}^k j_{13}^k + 2j_{22}^k j_{23}^k = 2 \sum_{l=1}^2 j_{l2}^k j_{l3}^k = \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_3 \partial x_2}
\end{aligned}$$

$$\begin{aligned}
\frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_3^2} &= \frac{\partial}{\partial x_3} \left\{ 2 \left[f_1(\mathbf{x}^k) + \frac{\partial f_1(\mathbf{x}^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_1(\mathbf{x}^k)}{\partial x_2} (x_2 - x_2^k) \right. \right. \\
&\quad \left. \left. + \frac{\partial f_1(\mathbf{x}^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_1(\mathbf{x}^k)}{\partial x_3} \right. \\
&\quad \left. + 2 \left[f_2(\mathbf{x}^k) + \frac{\partial f_2(\mathbf{x}^k)}{\partial x_1} (x_1 - x_1^k) + \frac{\partial f_2(\mathbf{x}^k)}{\partial x_2} (x_2 - x_2^k) \right. \right. \\
&\quad \left. \left. + \frac{\partial f_2(\mathbf{x}^k)}{\partial x_3} (x_3 - x_3^k) \right] \frac{\partial f_2(\mathbf{x}^k)}{\partial x_3} \right\} = 2 \frac{\partial f_1(\mathbf{x}^k)}{\partial x_3} \frac{\partial f_1(\mathbf{x}^k)}{\partial x_3} + 2 \frac{\partial f_2(\mathbf{x}^k)}{\partial x_3} \frac{\partial f_2(\mathbf{x}^k)}{\partial x_3} \\
&= 2j_{13}^k j_{13}^k + 2j_{23}^k j_{23}^k = 2 \sum_{l=1}^2 j_{l3}^k j_{l3}^k
\end{aligned}$$

$$\nabla^2 \tilde{Z}(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_1 \partial x_2} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_1 \partial x_3} \\ \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_2^2} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_2 \partial x_3} \\ \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_3 \partial x_1} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_3 \partial x_2} & \frac{\partial^2 \tilde{Z}(\mathbf{x})}{\partial x_3^2} \end{bmatrix} = 2 \begin{bmatrix} \sum_{l=1}^2 j_{l1}^k j_{l1}^k & \sum_{l=1}^2 j_{l1}^k j_{l2}^k & \sum_{l=1}^2 j_{l1}^k j_{l3}^k \\ \sum_{l=1}^2 j_{l1}^k j_{l2}^k & \sum_{l=1}^2 j_{l2}^k j_{l2}^k & \sum_{l=1}^2 j_{l2}^k j_{l3}^k \\ \sum_{l=1}^2 j_{l1}^k j_{l3}^k & \sum_{l=1}^2 j_{l2}^k j_{l3}^k & \sum_{l=1}^2 j_{l3}^k j_{l3}^k \end{bmatrix}$$

从普适性的角度出发来看， $\tilde{Z}(\mathbf{x})$ 是一个二次函数，则由上述特殊性展开的结果可以得到

$$\begin{aligned}\nabla \tilde{Z}(\mathbf{x}) &= \begin{bmatrix} \frac{\partial \tilde{Z}(\mathbf{x})}{\partial x_1} \\ \frac{\partial \tilde{Z}(\mathbf{x})}{\partial x_2} \\ \vdots \\ \frac{\partial \tilde{Z}(\mathbf{x})}{\partial x_n} \end{bmatrix} = 2 \begin{bmatrix} \sum_{l=1}^k \left[f_l(\mathbf{x}^k) + \sum_{i=1}^n \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) \right] \frac{\partial f_l(\mathbf{x}^k)}{\partial x_1} \\ \sum_{l=1}^k \left[f_l(\mathbf{x}^k) + \sum_{i=1}^n \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) \right] \frac{\partial f_l(\mathbf{x}^k)}{\partial x_2} \\ \vdots \\ \sum_{l=1}^k \left[f_l(\mathbf{x}^k) + \sum_{i=1}^n \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i} (x_i - x_i^k) \right] \frac{\partial f_l(\mathbf{x}^k)}{\partial x_n} \end{bmatrix} \\ &= 2 \begin{bmatrix} \sum_{l=1}^k f_l(\mathbf{x}^k) j_{l1}^k + \sum_{l=1}^k \sum_{i=1}^n j_{l1}^k j_{li}^k (x_i - x_i^k) \\ \sum_{l=1}^k f_l(\mathbf{x}^k) j_{l2}^k + \sum_{l=1}^k \sum_{i=1}^n j_{l2}^k j_{li}^k (x_i - x_i^k) \\ \vdots \\ \sum_{l=1}^k f_l(\mathbf{x}^k) j_{ln}^k + \sum_{l=1}^k \sum_{i=1}^n j_{ln}^k j_{li}^k (x_i - x_i^k) \end{bmatrix}\end{aligned}$$

根据 Jacobin 矩阵的定义及上式可以得到

$$\nabla^2 \tilde{Z}(\mathbf{x}^k) = \mathbf{H}(\mathbf{x}^k) = 2 \begin{bmatrix} \sum_{l=1}^m j_{l1}^k j_{l1}^k & \sum_{l=1}^m j_{l1}^k j_{l2}^k & \cdots & \sum_{l=1}^m j_{l1}^k j_{ln}^k \\ \sum_{l=1}^m j_{l2}^k j_{l1}^k & \sum_{l=1}^m j_{l2}^k j_{l2}^k & \cdots & \sum_{l=1}^m j_{l2}^k j_{ln}^k \\ \cdots & \cdots & \ddots & \cdots \\ \sum_{l=1}^m j_{ln}^k j_{l1}^k & \sum_{l=1}^m j_{ln}^k j_{l2}^k & \cdots & \sum_{l=1}^m j_{ln}^k j_{ln}^k \end{bmatrix} = 2(\mathbf{J}^k)^T \mathbf{J}^k$$

若矩阵 $(\mathbf{J}^k)^T \mathbf{J}^k$ 逆阵存在，并以此矩阵来近似函数 $z(\mathbf{x})$ 在点 $\mathbf{x}^k$ 处的 Hessian 矩阵，并连同下述式(1)代入下述式(2)即可得到高斯-牛顿迭代公式(3)。

$$\nabla Z(\mathbf{x}^k) = 2(\mathbf{J}^k)^T \mathbf{F}(\mathbf{x}^k) \quad (1)$$

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \mathbf{H}(\mathbf{x}^k)^{-1} \nabla f(\mathbf{x}^k) \quad (2)$$

$$\mathbf{x}^{k+1} = \mathbf{x}^k - ((\mathbf{J}^k)^T \mathbf{J}^k)^{-1} (\mathbf{J}^k)^T \mathbf{F}(\mathbf{x}^k) \quad (3)$$

改写上式得

$$((\mathbf{J}^k)^T \mathbf{J}^k)(\mathbf{x}^{k+1} - \mathbf{x}^k) = -(\mathbf{J}^k)^T \mathbf{F}(\mathbf{x}^k)$$

或

$$((\mathbf{J}^k)^T \mathbf{J}^k) \Delta \mathbf{x}^k = -(\mathbf{J}^k)^T \mathbf{F}(\mathbf{x}^k) \quad (4)$$

这是一个以

$$\Delta \mathbf{x}^k = [\Delta x_1^k, \Delta x_2^k, \dots, \Delta x_n^k]^T$$

为 n 个变量 n 个线性方程所构成的方程组，一般称为法方程。若法方程(4)的系数矩阵 $(\mathbf{J}^k)^T \mathbf{J}^k$ 非奇异，则采用高斯消去法或主元高斯消去法可以求解得到唯一解 $\Delta \mathbf{x}^k$ ，由此 $\mathbf{x}^{k+1}$ 也可以唯一确定，即

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \Delta \mathbf{x}^k$$

与前述的牛顿法一样，对高斯牛顿法进行修正，首先令

$$\mathbf{p}^k = \Delta \mathbf{x}^k = -((\mathbf{J}^k)^T \mathbf{J}^k)^{-1} (\mathbf{J}^k)^T \mathbf{F}(\mathbf{x}^k)$$

仅作为第 k 次搜索的一个搜索方向，这样由

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \lambda_k \mathbf{p}^k$$

来确定 $\mathbf{x}^{k+1}$ 。其中搜索步长 λ_k 应满足

$$z(\mathbf{x}^k + \lambda_k \mathbf{p}^k) \min_{\lambda_k} z(\mathbf{x}^k + \lambda_k \mathbf{p}^k)$$

高斯-牛顿法计算步骤归纳如下:

(1) 给定 $\mathbf{x}^0, \varepsilon, k = 0$

(2) 对 $l = 1, 2, \dots, m$ 求 $f_l(\mathbf{x}^k)$ 得向量

$$\mathbf{F}(\mathbf{x}^k) = [f_1(\mathbf{x}^k), f_2(\mathbf{x}^k), \dots, f_m(\mathbf{x}^k)]^T$$

(3) 对 $l = 1, 2, \dots, m; i = 1, 2, \dots, n$ 求

$$j_{lj}^k = \frac{\partial f_l(\mathbf{x}^k)}{\partial x_i}$$

从而得到

$$\mathbf{J}^k = \begin{bmatrix} j_{11}^k & j_{12}^k & \dots & j_{1n}^k \\ j_{21}^k & j_{22}^k & \dots & j_{2n}^k \\ \vdots & \vdots & \ddots & \vdots \\ j_{m1}^k & j_{m2}^k & \dots & j_{mn}^k \end{bmatrix}$$

(4) 解法方程

$$((\mathbf{J}^k)^T \mathbf{J}^k) \Delta \mathbf{x}^k = -(\mathbf{J}^k)^T \mathbf{F}(\mathbf{x}^k)$$

得 $\Delta \mathbf{x}^k$, 并使

$$\mathbf{p}^k = \Delta \mathbf{x}^k$$

(5)

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \lambda_k \mathbf{p}^k$$

使 λ_k 满足

$$z(\mathbf{x}^k + \lambda_k \mathbf{p}^k) \min_{\lambda_k} z(\mathbf{x}^k + \lambda_k \mathbf{p}^k)$$

(6) 若 $\|\mathbf{x}^{k+1} - \mathbf{x}^k\| \leq \varepsilon$, 则 $\mathbf{x}^* = \mathbf{x}^{k+1}$, 输出 $\mathbf{x}^*$, $z(\mathbf{x}^*)$, 停止计算, 否则 $k = k + 1$, 转入步骤(2)。

3.5 马夸特法(Marquardt method)

初始点 $\mathbf{x}^0$ 距离极小点不远时, 高斯-牛顿法求解非线性最小二乘问题非常有效。但若矩阵 $((\mathbf{J}^k)^T \mathbf{J}^k)$ 奇异或近似奇异时, 法方程无法求解, 迭代难以得到新的搜索点。为克服这一缺点, 马夸特对法方程进行改造, 其主要思想就是加大矩阵 $((\mathbf{J}^k)^T \mathbf{J}^k)$ 主对角元素的值, 即

$$((\mathbf{J}^k)^T \mathbf{J}^k + \lambda \mathbf{I}) \Delta \mathbf{x}^k = -(\mathbf{J}^k)^T \mathbf{F}(\mathbf{x}^k)$$

上式中 $\mathbf{I}$ 为单位矩阵, $\lambda > 0$ 称为阻尼因子。改造后法方程的系数矩阵 $((\mathbf{J}^k)^T \mathbf{J}^k + \lambda \mathbf{I})$ 为一正定矩阵, 则其逆一定存在, 那么法方程一定有解。因此, 马夸特法(Marquardt method)的搜索方向为

$$\mathbf{p}^k = \Delta \mathbf{x}^k = -((\mathbf{J}^k)^T \mathbf{J}^k + \lambda \mathbf{I})^{-1} (\mathbf{J}^k)^T \mathbf{F}(\mathbf{x}^k)$$

上式中若 $\lambda = 0$ 时即为高斯-牛顿方向。当 λ 足够大时, λ 方向逐渐趋向于负梯度方向, 负梯度方向即为某点的最速下降方向, 但从全局来看收敛速度非常缓慢, 不是一个理想方向, 而高斯-牛顿方向从全局看是收敛速度很快的方向。因此, 保持目标函数下降的情况下, λ 值应尽可能小, 使得搜索方向靠近高斯-牛顿方向, 加快收敛速度。由此可看出马夸特法的关键是合理选取阻尼因子 λ , 既要保持目标函数下降, 又要使得收敛速度加快。马夸特法有时也称为阻尼最小二乘法。阻尼因子的选取有多种方法, 在此介绍一种简单易行的方法, 即一边迭代一边调整阻尼因子的方法, 阻尼因子过大则缩小, 过小则放大。

选取初始阻尼因子 λ_0 (如取 $\lambda_0 = 0.1$ or 0.01) 和一个大于 1 的整数 μ (比如 $\mu = 2, 5, 10 \dots$)。

令 λ_{k-1} 为第 $k-1$ 次迭代的阻尼因子 λ 值, 第 k 次迭代时 $\lambda_k = \frac{\lambda_{k-1}}{\mu}$ 计算出马夸特搜索方向 $\mathbf{p}^k$,

然后再求出 $\mathbf{x}^{k+1} = \mathbf{x}^k + \lambda_k \mathbf{p}^k$ 。此时若目标函数值 $z(\mathbf{x}^{k+1}) < z(\mathbf{x}^k)$, 那么 $\lambda_k = \frac{\lambda_{k-1}}{\mu}$ 即为此次迭代的阻尼因子值; 若 $z(\mathbf{x}^{k+1}) > z(\mathbf{x}^k)$, 此时需加大 λ 值, 即可让 $\lambda_k = \mu \lambda_{k-1}$ 再计算 $\mathbf{p}^k$ 和 $\mathbf{x}^{k+1}$, 若仍有 $z(\mathbf{x}^{k+1}) > z(\mathbf{x}^k)$, 则继续加大 λ 值, 即 $\lambda_k = \mu^2 \lambda_{k-1}, \lambda_k = \mu^3 \lambda_{k-1}, \dots, \lambda_k = \mu^\omega \lambda_{k-1}$, 直到找到一个最小的 ω 使得 $z(\mathbf{x}^{k+1}) < z(\mathbf{x}^k)$ 成立为止。由于当 $\lambda = 0 \rightarrow +\infty$ 时, $\mathbf{p}^k \rightarrow -\nabla z(\mathbf{x}^k)$, 因此总可找到上述最小的 ω 。

3.6 Cases-Gilliland 曲线拟合

吉利兰关联图数据如表所示

i	x_i	y_i	i	x_i	y_i
1	0.01	0.69	6	0.3	0.37
2	0.02	0.67	7	0.4	0.21
3	0.04	0.62	8	0.5	0.24
4	0.1	0.54	9	0.9	0.16
5	0.2	0.45	10	1.0	0.0

函数关系为

$$f(\mathbf{x}) = x_1 + x_2 m^{x_3} \quad (\mathbf{x} = (x_1, x_2, x_3)^T)$$

则目标函数为

$$\min z(\mathbf{x}) = \min \sum_{l=1}^k f_l^2(\mathbf{x}) = \min \sum_{l=1}^{10} f_l^2(\mathbf{x}) = \min \sum_{l=1}^{10} [(x_1 + x_2 m_i^{x_3}) - y_i]^2$$

函数 $f_l(\mathbf{x})$ 的梯度

$$\nabla f_l(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_l(\mathbf{x})}{\partial x_1} \\ \frac{\partial f_l(\mathbf{x})}{\partial x_2} \\ \frac{\partial f_l(\mathbf{x})}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 1 \\ m_i^{x_3} \\ x_2 m_i^{x_3} \ln m_i \end{bmatrix}$$

取 $\lambda_0 = 0.01, \mu = 2.0, \mathbf{x}^0 = [0.6, -0.4, 0.3]^T$, 目标函数 $z(\mathbf{x}^0) = 0.1864$, $\mathbf{x}^0$ 点处的 Jacobin 矩阵为

$$J(\mathbf{x}^0) = \begin{bmatrix} 1 & 0.2512 & 0.4627 \\ 1 & 0.3092 & 0.4839 \\ 1 & 0.3807 & 0.4902 \\ 1 & 0.5012 & 0.4616 \\ 1 & 0.6170 & 0.3972 \\ 1 & 0.6908 & 0.3356 \\ 1 & 0.7597 & 0.2784 \\ 1 & 0.8123 & 0.2252 \\ 1 & 0.9689 & 0.0408 \\ 1 & 0.0000 & 0.0000 \end{bmatrix}$$

$$\mathbf{F}(\mathbf{x}^0) = \begin{bmatrix} -0.1905 \\ -0.1937 \\ -0.1723 \\ -0.1405 \\ -0.0968 \\ -0.0487 \\ 0.0861 \\ 0.0351 \\ 0.0524 \\ 0.2000 \end{bmatrix}$$

$$-\mathbf{J}(\mathbf{x}^0)^T \mathbf{F}(\mathbf{x}^0) = [0.4688 \quad -0.0073 \quad 0.3520]^T$$

$$\mathbf{J}(\mathbf{x}^0)^T \mathbf{J}(\mathbf{x}^0) = \begin{bmatrix} 10 & 6.2970 & 3.1757 \\ 6.2970 & 4.5968 & 1.5968 \\ 3.1757 & 1.5968 & 1.3020 \end{bmatrix}$$

$$\mathbf{J}(\mathbf{x}^0)^T \mathbf{J}(\mathbf{x}^0) + \lambda_0 \mathbf{I} = \begin{bmatrix} 10.01 & 6.2970 & 3.1757 \\ 6.2970 & 4.6068 & 1.6068 \\ 3.1757 & 1.5968 & 1.3020 \end{bmatrix}$$

得到法方程为

$$\begin{bmatrix} 10.01 & 6.2970 & 3.1757 \\ 6.2970 & 4.6068 & 1.6068 \\ 3.1757 & 1.5968 & 1.3020 \end{bmatrix} \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \\ \Delta x_3 \end{bmatrix} = \begin{bmatrix} 0.4688 \\ -0.0073 \\ 0.3520 \end{bmatrix}$$

$$\Delta \mathbf{x}^0 = [0.1434 \quad -0.2946 \quad 0.2796]^T$$

$$\mathbf{x}^1 = \mathbf{x}^0 + \Delta \mathbf{x}^0 = [0.7434 \quad -0.6946 \quad 0.5796]^T$$

目标函数值

$$z(\mathbf{x}^1) = 0.0263 < z(\mathbf{x}^0)$$

完成一次迭代，由于 $z(\mathbf{x}^1) < z(\mathbf{x}^0)$ ， $\lambda_1 = \frac{\mu}{2.0} = 0.005$ ，进行第二次迭代，所得结果为

$$\mathbf{J}(\mathbf{x}^1) = \begin{bmatrix} 1 & 0.0693 & 0.2217 \\ 1 & 0.1036 & 0.2815 \\ 1 & 0.1548 & 0.3461 \\ 1 & 0.2633 & 0.4211 \\ 1 & 0.3935 & 0.4398 \\ 1 & 0.4977 & 0.4162 \\ 1 & 0.5880 & 0.3742 \\ 1 & 0.6692 & 0.3222 \\ 1 & 0.9408 & 0.0688 \\ 1 & 1.0000 & 0.0000 \end{bmatrix}$$

$$\mathbf{F}(\mathbf{x}^1) = \begin{bmatrix} 0.0053 \\ 0.0015 \\ 0.0159 \\ 0.0206 \\ 0.0202 \\ 0.0278 \\ 0.1250 \\ 0.0387 \\ -0.0700 \\ 0.0489 \end{bmatrix}$$

$$-\mathbf{J}(\mathbf{x}^1)^T \mathbf{F}(\mathbf{x}^1) = [-0.2338 \quad -0.1126 \quad -0.0906]^T$$

$$\mathbf{J}(\mathbf{x}^0)^T \mathbf{J}(\mathbf{x}^0) = \begin{bmatrix} 10 & 4.6801 & 2.8916 \\ 4.6801 & 3.1899 & 1.0895 \\ 2.8916 & 1.0895 & 1.0407 \end{bmatrix}$$

$$J(\boldsymbol{x}^1)^T J(\boldsymbol{x}^1) + \lambda_1 \boldsymbol{I} = \begin{bmatrix} 10.005 & 4.6801 & 2.8916 \\ 4.6801 & 3.1949 & 1.0895 \\ 2.8916 & 1.0895 & 1.0457 \end{bmatrix}$$

得到法方程为

$$\begin{bmatrix} 10.005 & 4.6801 & 2.8916 \\ 4.6801 & 3.1949 & 1.0895 \\ 2.8916 & 1.0895 & 1.0457 \end{bmatrix} \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \\ \Delta x_3 \end{bmatrix} = \begin{bmatrix} -0.2338 \\ -0.1126 \\ -0.0906 \end{bmatrix}$$

$$\Delta \boldsymbol{x}^1 = [0.0478 \ -0.0475 \ -0.1692]^T$$

$$\boldsymbol{x}^2 = \boldsymbol{x}^1 + \Delta \boldsymbol{x}^1 = [0.7912 \ -0.7420 \ 0.4103]^T$$

目标函数值

$$z(\boldsymbol{x}^2) = 0.0197 < z(\boldsymbol{x}^1)$$