

引言：机器学习概要


周 达

zhouda@xmu.edu.cn


什么是机器学习(Machine Learning)

- “Learning is any process by which a system improves performance from experience” (by Herbert Simon)
- Machine Learning is the study of algorithms that improve their performance P at some task T with experience E . (by Tom Mitchell)

机器学习与传统计算机程序的比较




Machine Learning



机器学习和传统统计学的比较


Glossary

Machine learning	Statistics
network, graphs	model
weights	parameters
learning	fitting
generalization	test set performance
supervised learning	regression/classification
unsupervised learning	density estimation, clustering
large grant = \$1,000,000	large grant= \$50,000
nice place to have a meeting: Snowbird, Utah, French Alps	nice place to have a meeting: Las Vegas in August



机器学习有哪些主要的应用场景

- 模式识别 （人脸识别、手写识别、机器翻译、AI影像等）
- 模式生成 （图像生成、文本生成、结构生成等）
- 模型预测 （时间序列预测等）
- 智能决策 （AlphaGo等）






机器学习有哪些学习渠道



- <https://www.coursera.org/learn/machine-learning> (吴恩达 《机器学习》 公开课, 入门级)
- <https://davidrosenberg.github.io/ml2019/#home> (纽约大学数据科学项目的核心课程 《Machine Learning》, 进阶级)
- <https://tw.coursera.org/learn/ntumlone-mathematicalfoundations>
- <https://www.coursera.org/learn/ntumlone-algorithmicfoundations> (台湾大学林轩田的 《机器学习基石》, 中文)
- 其它资源 (B站, 网易云课堂等等)

机器学习有哪些教材

太多




如何兼顾机器学习实践




机器学习的几种类别划分

- 按照是否能自动进行特征提取
 - 深度学习（自动化特征提取）
 - 特征工程+机器学习（人工特征提取）






机器学习的几种类别划分

- 按照是否有监督信息
 - 监督学习
 - 无监督学习
 - 半监督学习



机器学习的几种类别划分

- 监督学习的进一步细分
 - 判别模型和生成模型
 - 分类和回归



机器学习的几种类别划分

- 其它类型



- 强化学习
- 迁移学习
- 联邦学习
- 在线学习
- 因果学习

- 可解释学习
- 元学习
- 对抗学习
- 对偶学习
- 量子学习

学习机器学习的三个层次

	认知	实践
入门级 (本科)	快速熟悉基本概念、常用模型和算法	会使用现有软件包处理一些标准化数据集， 掌握一些简单的调参技巧
进阶级 (硕士)	掌握模型背后的原理以及特点，进入若干特定领域，初步具备对特定方法提出性能改进的能力	能借助常用框架搭建模型，具备一定的算法开发能力，针对特定领域积累一定的调参技巧
专家级 (博士)	对数学原理有更深入的理解，进入特定领域的前沿地带，具备较强的方法学创新能力	能实现较为底层的优化迭代算法，具备较强的算法开发能力和工程经验

数据科学的核心挑战：高维数据



维数灾难

- **高维数据稀疏化问题**：“N个点在 p 维单位球内随机分布，则随着 p 的增大，这些点会越来越远离单位球的中心，转而往外缘分散”
- **高维空间计算量问题**：“随着维数的增加，向量的计算量呈指数倍增”

如何应对维数灾难的挑战？

核心：特征提取（表示）

- 第一层涵义：如何把数据向量化？



- 第二层涵义：如何对向量化数据进行降维表示？


两种学科的比较

	高维统计	机器学习
数据表示	矩、分位数等	特征工程、深度学习
特征选择	线性模型：Lasso	Feature importance and interaction
可视化	线性方法：PCA	流形学习：t-SNE, UMAP
特点总结	理论优美、解释性好、灵活性差	工程化、解释性亟待研究、应用灵活

思考：为什么降维往往有效？



因为信息冗余

- 对于特定任务，关键变量可能并不多。
- 高维数据实际上是由一个低维流形映射到高维空间。



思考：为什么降维往往有效？


偏差方差平衡(bias-variance tradeoff)



$$\mathbb{E}_{D, \epsilon} \left[(y - \hat{f}(x; D))^2 \right] = \left(\text{Bias}_D [\hat{f}(x; D)] \right)^2 + \text{Var}_D [\hat{f}(x; D)] + \sigma^2$$


如何设计一个机器学习问题（监督学习）

- 数据（训练集、验证集、测试集）
- 建模（模型、策略、算法）
- 评估（指标体系）



数据

- 训练集（训练机器学习模型参数）
- 验证集（调整超参数）
- 测试集（评估模型泛化能力）



- 一般假定数据同分布，若不同分布，则要采取迁移学习等方法

数据

- 预处理之特征提取

Raw Input

$\mathcal{X}$ $\xrightarrow{x}$

Feature
Extraction

$\xrightarrow{\phi(x)}$

$\mathbb{R}^d$

Feature Vector

abc@gmail.com



feature extractor

arbitrary!

length>10	: 1
fracOfAlpha	: 0.85
contains_@	: 1
endsWith_com	: 1
endsWith_org	: 0

数据

- 预处理之数据增强：利用算法来扩展训练数据
- 常用的数据增强方法包括：自监督、对抗学习、主动学习、过采样方法等



Enlarge your Dataset

建模之模型

- **模型**：所要学习的条件概率或预测函数
- **假设空间**：满足假设的所有条件概率或预测函数类所组成的函数空间

例如：所有的线性函数组成一个假设空间；所有的神经网络模型组成一个假设空间。

建模之策略

- 损失函数 (loss function)
- 风险函数: 损失函数的数学期望
- 经验风险函数: 风险函数在训练集中的样本平均
- 经验风险最小化与结构风险最小化

$$\min_{f \in F} \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))$$

$$\min_{f \in F} \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) + \lambda J(f)$$

建模之算法

- **算法：**学习模型的具体计算方法；基于训练数据集和策略，从假设空间中选择最优模型的具体算法。
- 机器学习问题最后都会归结为一个最优化问题，且通常解析解不存在，需要数值求解。

建模三要素（模型、策略、算法）

	模型	策略	算法
经典线性回归	线性模型	经验风险最小化（最小二乘法）	解析解或梯度下降等
Lasso	线性模型	结构风险最小化（加入L1惩罚项）	最小角度回归算法或坐标下降等

评估

- 训练误差和测试误差;
- 评估所使用的误差函数不一定是训练时使用的损失函数;
- 分类问题的评估;
- 回归问题的评估;
- 非监督学习问题的评估

小结与讨论

- 机器学习是处理高维数据的重要方法;
- 实现自动化特征提取是机器学习的难点（深度学习）;
- 克服数据标注的高成本是机器学习面临的又一个难点;
- 奥卡姆剃刀原则